Predicción conforme

Guía teórica

José Diego Martínez Hernández

Octubre de 2026

Resumen

La predicción conforme convierte cualquier modelo en un conjunto predictivo con cobertura marginal en muestra finita, bajo un solo supuesto: intercambiabilidad de los puntajes. Esta guía sigue la estructura del tutorial de Angelopoulos y Bates: primero el objetivo y qué conjuntos queremos, luego un algoritmo concreto con un clasificador de dígitos, después la receta general con ejemplos de puntajes de no conformidad, el ordenamiento de los puntajes y la intercambiabilidad como respuesta a por qué todos los huecos son igual de probables. Sólo entonces, con el supuesto y los puntajes ya presentados, el ejemplo de 19 puntajes y el teorema de cobertura con su demostración completa. Siguen la diferencia entre cobertura marginal y condicional, la variación entre calibraciones, el crédito con la cobertura por clase, las elecciones de 2012 como caso principal (con un umbral por tipo de sección) y los p-valores conformes. El conteo de 2018 queda como complemento. Todas las demostraciones están explícitas. Los programas de cada ejemplo están en la carpeta `aplicaciones` del repositorio.

Índice

1. La pregunta y el objetivo **3**

2. El punto de comparación clásico **4**

3. Un primer algoritmo: clasificar dígitos **5**

4. Puntajes de no conformidad **6**

5. Ordenar los puntajes de calibración **8**

6. Intercambiabilidad: por qué los huecos son igual de probables **10**

7. El ejemplo de 19 puntajes, a fondo **11**

8. El teorema y su demostración **13**

9. Muestra finita **15**

10. Volvamos a los dígitos: tamaño y grupos **15**

11.Cobertura marginal y cobertura condicional **16**

12.Variación entre calibraciones: la distribución Beta **17**

13.Crédito **19**

14.Elecciones 2012: el caso principal **22**

15.Complemento: cuando el sorteo no basta, el conteo de 2018 **25**

16.P-valores conformes **27**

17.Preguntas probables **30**

A. Cuántos datos se usaron en cada ejemplo **32**

B. Datos y programas **33**

Fuentes **33**

1. La pregunta y el objetivo

1.1. Por qué un conjunto

Un predictor puntual $\widehat{f}(x)$ responde "¿qué valor espero?". Pero en las decisiones importa también qué otras respuestas son plausibles. Ante un dígito borroso, "es un 1" es menos útil que "es un 1, un 4 o un 5, y la respuesta correcta está en esa lista el 90 % de las veces". Un conjunto predictivo $C(x)$ responde "¿qué respuestas son compatibles con lo aprendido, al nivel de cobertura elegido?". Para una respuesta real, $C(x)$ suele ser un intervalo; para una etiqueta, un subconjunto de etiquetas. La predicción conforme toma la incertidumbre *heurística* de cualquier modelo (probabilidades, residuos, cuantiles) y la convierte en un conjunto con una garantía precisa (Angelopoulos y Bates, 2023).

Confianza y predicción. Un intervalo de confianza se refiere a un parámetro, como $\mathbb{E}(Y \mid X = x)$, y se angosta cuando crece la muestra. Un intervalo de predicción se refiere a una observación nueva: aunque el modelo se conociera sin error, la variabilidad propia de Y no desaparece. La predicción conforme construye conjuntos de predicción.

1.2. El objetivo, leído con cuidado

Notación. Los datos son $Z_i = (X_i, Y_i)$. Hay tres bloques: un *entrenamiento* T que ajusta el modelo; una *calibración* $D_{\text{cal}} = \{Z_1, \ldots, Z_n\}$ que el modelo no vio y que fija un umbral; y un *caso nuevo* Z_{n+1} del que sólo se observa X_{n+1}. Cualquier aleatoriedad del ajuste (semillas, validación cruzada) se considera parte de T.

El objetivo es que, para un nivel $0 < \alpha < 1$ elegido de antemano,

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1})\} \geq 1 - \alpha.$$

- α es la tasa de error tolerada: $\alpha = 0.10$ pide 90 %.
- La probabilidad es sobre *todo lo aleatorio*: la calibración y el caso nuevo (y, si no se condiciona, el entrenamiento). Es una propiedad del procedimiento repetido; no asigna probabilidad $1 - \alpha$ a cada conjunto ya observado ni a cada individuo concreto.
- Con "$\geq$" se habla de cobertura *conservadora*; con "$=$", de cobertura *exacta*.
- Como promedia sobre todos los casos, se llama cobertura *marginal*. La diferencia con una cobertura condicional a cada x se discute en la sección 11.

1.3. Qué conjuntos queremos

La cobertura sola no basta.

Proposición 1.1 (un conjunto exacto e inútil)**.** *Sea $\mathcal{Y}$ el espacio de respuestas y B una Bernoulli$(1-\alpha)$ independiente de todo. El conjunto $C(x) = \mathcal{Y}$ si $B = 1$ y $C(x) = \varnothing$ si $B = 0$ tiene cobertura exactamente $1 - \alpha$ para cualquier distribución.*

Demostración. $Y_{n+1} \in C(X_{n+1})$ si y sólo si $B = 1$, que tiene probabilidad $1 - \alpha$. ■

Este conjunto no usa los datos y no dice nada. Por eso se piden tres cosas (Angelopoulos y Bates, 2023):

1. **Cobertura** al menos $1-\alpha$ y cercana a la exacta.
2. **Tamaño pequeño**, para que quien decide vea una lista corta de respuestas plausibles.
3. **Adaptatividad**: conjuntos pequeños para casos fáciles y grandes para casos difíciles, de modo que el tamaño informe sobre la dificultad.

La calibración se encarga de (1) para cualquier modelo (sección 8). El modelo y el puntaje deciden qué tan bien se cumplen (2) y (3) (sección 4).

2. El punto de comparación clásico

2.1. Regresión lineal normal

Sea $\mathbf{X}$ la matriz de diseño de entrenamiento, de $m \times d$ y rango completo $d < m$, y supóngase

$$Y_i = x_i^\top \beta + \varepsilon_i, \qquad \varepsilon_i \overset{\text{iid}}{\sim} N(0, \sigma^2).$$

Proposición 2.1. *Para una observación nueva $Y = x^\top\beta + \varepsilon$, con $\varepsilon \sim N(0,\sigma^2)$ independiente del entrenamiento, el intervalo*

$$x^\top \widehat{\beta} \;\pm\; t_{m-d,1-\alpha/2}\, \widehat{\sigma}\sqrt{1 + x^\top(\mathbf{X}^\top\mathbf{X})^{-1}x}$$

tiene cobertura exactamente $1-\alpha$, condicionada al diseño y a x.

Demostración. Con $\widehat{\beta} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{Y}$ se tiene $\widehat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1})$. El error de predicción $e = Y - x^\top\widehat{\beta} = \varepsilon - x^\top(\widehat{\beta}-\beta)$ es suma de dos normales independientes centradas, así que

$$e \sim N\big(0,\ \sigma^2[1 + x^\top(\mathbf{X}^\top\mathbf{X})^{-1}x]\big).$$

El estimador $\widehat{\sigma}^2 = \|\mathbf{Y} - \mathbf{X}\widehat{\beta}\|^2/(m-d)$ cumple $(m-d)\widehat{\sigma}^2/\sigma^2 \sim \chi^2_{m-d}$ y es independiente de $\widehat{\beta}$ (teorema de Cochran: los residuos y los ajustados viven en subespacios ortogonales) y de ε. Por tanto

$$\frac{e}{\widehat{\sigma}\sqrt{1 + x^\top(\mathbf{X}^\top\mathbf{X})^{-1}x}} = \frac{e/(\sigma\sqrt{1 + x^\top(\mathbf{X}^\top\mathbf{X})^{-1}x})}{\sqrt{\widehat{\sigma}^2/\sigma^2}} \sim t_{m-d},$$

cociente de una normal estándar entre la raíz de una $\chi^2_{m-d}/(m-d)$ independiente. La probabilidad de que $|t_{m-d}| \le t_{m-d,1-\alpha/2}$ es $1-\alpha$. ∎

El "1" dentro de la raíz es el ruido de la observación nueva; sin él se obtiene el intervalo de confianza para la media. La exactitud descansa en normalidad, linealidad y homocedasticidad.

La pregunta de la charla. ¿Cómo construir un conjunto cuando el predictor es un boosting, una red o una regresión mal especificada? (Para respuestas binarias, la referencia clásica correspondiente se presenta junto con el crédito, en la sección 13.) Conformal cambia el fundamento de la garantía: ya no la saca del modelo, sino de los rangos de puntajes intercambiables. A cambio, la garantía es marginal, no para cada x.

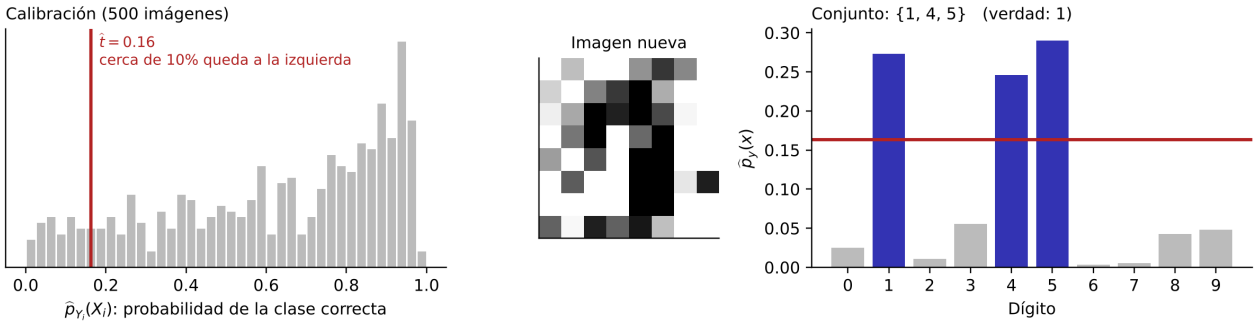
3. Un primer algoritmo: clasificar dígitos

Antes de la teoría, un algoritmo concreto que se entiende solo.

Datos. 1,797 imágenes de dígitos escritos a mano, de 8×8 píxeles con intensidades de 0 a 16 (conjunto de dígitos de UCI incluido en `scikit-learn`). A cada imagen se le asigna al azar un nivel de ruido gaussiano: ninguno, medio (desviación 4) o alto (desviación 8), recortando a $[0, 16]$. El mismo mecanismo se aplica a entrenamiento, calibración y prueba, así que los datos siguen siendo intercambiables. Modelo: regresión logística multinomial con penalización, que da probabilidades $\widehat{p}_0(x), \ldots, \widehat{p}_9(x)$. Particiones al azar de 600 imágenes de entrenamiento, 500 de calibración y 697 de prueba; $\alpha = 0.10$.

El algoritmo.

1. Para cada imagen de calibración, anotar la probabilidad que el modelo le dio a la clase *correcta*: $\widehat{p}_{Y_i}(X_i)$, $i = 1, \ldots, n$.
2. Tomar como umbral $\widehat{t}$ el valor que deja por debajo a cerca del 10 % de esas probabilidades. Con la corrección de muestra finita, $\widehat{t}$ es la m-ésima menor de ellas, con $m = \lfloor \alpha(n+1) \rfloor$; para $n = 500$, $m = 50$.
3. Para una imagen nueva, $C(x) = \{y : \ \widehat{p}_y(x) \geq \widehat{t}\}$.



En la partición mostrada, $\widehat{t} = 0.16$: 9.8 % de las probabilidades de calibración quedaron por debajo. La imagen nueva recibe las tres etiquetas cuya probabilidad supera la línea: $\{1, 4, 5\}$.

El resultado. En las 697 imágenes de prueba, promediando 100 particiones, el conjunto contiene la etiqueta correcta 89.9 % de las veces, aunque el modelo sólo acierta con su etiqueta más probable 81 % de las veces. ¿Por qué justo 90 %, sin saber nada del modelo ni de las imágenes? Responder eso es el objetivo de las secciones 5 a 8.

La intuición. Si el modelo casi siempre le da probabilidad alta a la clase correcta, el umbral es alto y los conjuntos son chicos. Si a menudo se equivoca, el umbral baja y los conjuntos crecen. El conjunto incluye la etiqueta correcta exactamente cuando su probabilidad no cae en el 10 % más bajo, y si la imagen nueva "se parece" a las de calibración, eso pasa 90 % de las veces.

Proposición 3.1 (es split conformal con el puntaje $1 - \widehat{p}_y$)**.** *Con* $s_T(x, y) = 1 - \widehat{p}_y(x)$, $k = \lceil (n+1)(1-\alpha) \rceil \leq n$ *y* $\widehat{q} = S_{(k)}$, *se tiene* $\widehat{t} = 1 - \widehat{q}$ *y* $C(x) = \{y : s_T(x, y) \leq \widehat{q}\}$.

Demostración. La función $u \mapsto 1 - u$ invierte el orden: el k-ésimo menor de los $S_i = 1 - \widehat{p}_{Y_i}(X_i)$ es uno menos el k-ésimo *mayor* de las probabilidades, que es la $(n + 1 - k)$-ésima menor. Como

$n+1-k = n+1-\lceil (n+1)(1-\alpha)\rceil = \lfloor \alpha(n+1)\rfloor = m$, resulta $\widehat{q} = 1-\widehat{t}$. Y $\widehat{p}_y(x) \geq \widehat{t} \iff 1-\widehat{p}_y(x) \leq 1-\widehat{t} = \widehat{q}$. ■

Así el primer algoritmo es un caso de la receta general de la sección 4, y la garantía saldrá del Teorema 8.2.

4. Puntajes de no conformidad

4.1. La receta general

El algoritmo de los dígitos es un caso de un procedimiento que sirve para cualquier problema (Angelopoulos y Bates, 2023):

0. Identificar una noción *heurística* de incertidumbre del modelo: probabilidades, residuos, cuantiles estimados.
1. Convertirla en un puntaje de no conformidad $s_T(x, y)$.
2. Calcular $\widehat{q}$, el cuantil corregido de los puntajes de calibración (sección 5).
3. Formar el conjunto $C(x) = \{y : \ s_T(x, y) \leq \widehat{q}\}$.

En los dígitos, el paso 0 son las probabilidades del modelo y el paso 1 es $s_T = 1 - \widehat{p}_y$ (Proposición 3.1).

4.2. La idea

Un *puntaje de no conformidad* es una función $s_T : \mathcal{X} \times \mathcal{Y} \to \mathbb{R} \cup \{+\infty\}$, fijada con el entrenamiento, que mide qué tan rara es la respuesta y para el caso x. Valores grandes significan poca compatibilidad. Dado el umbral $\widehat{q}$, el conjunto es siempre

$$C(x) = \{y \in \mathcal{Y} : \ s_T(x, y) \leq \widehat{q}\}.$$

Dos hechos organizan todo lo que sigue.

Proposición 4.1 (la garantía no depende del puntaje)**.** *Para cualquier puntaje fijado con T, si los datos son intercambiables dado T, el Teorema 8.2 se aplica.*

Demostración. El teorema sólo usa que los $S_i = s_T(X_i, Y_i)$ sean intercambiables, y eso lo da el Lema 6.4 para cualquier s_T medible fijada con T. ■

Proposición 4.2 (invariancia ante transformaciones crecientes)**.** *Si h es estrictamente creciente, usar $h \circ s_T$ en lugar de s_T produce exactamente el mismo conjunto $C(x)$.*

Demostración. Una función estrictamente creciente preserva el orden: el k-ésimo menor de los $h(S_i)$ es $h(S_{(k)})$, así que el nuevo umbral es $h(\widehat{q})$ (con $h(+\infty) = +\infty$). Y $h(s_T(x, y)) \leq h(\widehat{q}) \iff s_T(x, y) \leq \widehat{q}$. ■

Por eso $1 - \widehat{p}_y$, $-\widehat{p}_y$ y $-\log \widehat{p}_y$ dan el mismo conjunto en clasificación. Lo que sí cambia el conjunto es cambiar *qué se ordena*: residuos absolutos contra residuos escalados, probabilidad de la etiqueta contra masa acumulada. El puntaje decide la forma y el tamaño de $C(x)$, es decir, su *utilidad*.

Receta para invertir un puntaje. Para saber qué forma tiene $C(x)$ se resuelve la desigualdad $s_T(x, y) \le \widehat{q}$ en y. Los ejemplos siguientes lo hacen explícitamente.

4.3. Regresión

Ejemplo 4.3 (residuo absoluto)**.** $s_T(x, y) = |y - \widehat{f}_T(x)|$. Entonces $|y - \widehat{f}_T(x)| \le \widehat{q} \iff \widehat{f}_T(x) - \widehat{q} \le y \le \widehat{f}_T(x) + \widehat{q}$, y

$$C(x) = [\widehat{f}_T(x) - \widehat{q},\ \widehat{f}_T(x) + \widehat{q}].$$

El ancho $2\widehat{q}$ es el mismo para todo x. Si el modelo está mal especificado, $\widehat{q}$ crece y la banda se ensancha en todas partes, pero la cobertura marginal se conserva.

Ejemplo 4.4 (residuo con signo: intervalos de un lado)**.** $s_T(x, y) = y - \widehat{f}_T(x)$ da $C(x) = (-\infty, \widehat{f}_T(x) + \widehat{q}]$: una cota superior con garantía, útil cuando sólo importa no subestimar (inventarios, demanda). Con $s_T = \widehat{f}_T(x) - y$ se obtiene la cota inferior.

Ejemplo 4.5 (residuo escalado)**.** Con un modelo de escala $\widehat{\sigma}_T(x) > 0$ ajustado en entrenamiento (por ejemplo, una regresión de $|y - \widehat{f}_T(x)|$ sobre x),

$$s_T(x, y) = \frac{|y - \widehat{f}_T(x)|}{\widehat{\sigma}_T(x)} \quad \Longrightarrow \quad C(x) = [\widehat{f}_T(x) - \widehat{q}\,\widehat{\sigma}_T(x),\ \widehat{f}_T(x) + \widehat{q}\,\widehat{\sigma}_T(x)].$$

El ancho es $2\widehat{q}\,\widehat{\sigma}_T(x)$: mayor donde el modelo espera equivocarse más. Así se acerca a la cobertura por regiones sin garantizarla.

Ejemplo 4.6 (regresión cuantílica conformalizada, CQR)**.** Se ajustan en T dos cuantiles condicionales, $\widehat{\ell}_T(x) \approx q_{\alpha/2}(x)$ y $\widehat{u}_T(x) \approx q_{1-\alpha/2}(x)$, y se usa

$$s_T(x, y) = \max\{\widehat{\ell}_T(x) - y,\ y - \widehat{u}_T(x)\}.$$

Como el máximo de dos números es $\le \widehat{q}$ si y sólo si ambos lo son,

$$s_T(x, y) \le \widehat{q} \iff y \ge \widehat{\ell}_T(x) - \widehat{q} \ \text{ y } \ y \le \widehat{u}_T(x) + \widehat{q} \iff y \in [\widehat{\ell}_T(x) - \widehat{q},\ \widehat{u}_T(x) + \widehat{q}].$$

El puntaje es positivo cuando y cae fuera de la banda estimada y negativo cuando cae dentro. Por eso $\widehat{q}$ puede ser negativo: si la banda estimada era demasiado ancha, la calibración la encoge. Si los extremos se cruzan el conjunto es vacío; no deben intercambiarse.

Ejemplo 4.7 (proporciones: el voto de una casilla)**.** Si $y \in (0, 1)$ es una proporción, el residuo absoluto puede producir intervalos fuera de $[0, 1]$. Con $\operatorname{logit}(u) = \log\{u/(1-u)\}$ y $\widehat{f}_T(x) \in (0, 1)$,

$$s_T(x, y) = |\operatorname{logit} y - \operatorname{logit} \widehat{f}_T(x)| \quad \Longrightarrow \quad C(x) = [\operatorname{logit}^{-1}(\operatorname{logit} \widehat{f}_T(x) - \widehat{q}),\ \operatorname{logit}^{-1}(\operatorname{logit} \widehat{f}_T(x) + \widehat{q})],$$

porque logit es creciente y biyectiva de $(0, 1)$ en $\mathbb{R}$. El intervalo queda dentro de $(0, 1)$ y es asimétrico: más angosto cerca de cero o de uno. Si y puede valer exactamente 0 o 1, se aplica antes un pequeño corrimiento fijo.

Ejemplo 4.8 (densidad predictiva)**.** Si el modelo da una densidad condicional $\widehat{p}_T(y \mid x)$, el puntaje $s_T(x, y) = -\widehat{p}_T(y \mid x)$ produce

$$C(x) = \{y :\ \widehat{p}_T(y \mid x) \ge -\widehat{q}\},$$

un conjunto de nivel de la densidad (la región de mayor densidad). Con una densidad bimodal puede ser la unión de dos intervalos: el conjunto no tiene por qué ser un intervalo. Una predictiva bayesiana sirve igual, y así una predictiva posterior recibe una garantía frecuentista (Fong y Holmes, 2021).

Ejemplo 4.9 (función de distribución predictiva)**.** Si el modelo da una distribución condicional $\widehat{F}_T(y \mid x)$ continua y creciente en y, $s_T(x, y) = |\widehat{F}_T(y \mid x) - 1/2|$ da

$$C(x) = [\widehat{F}_T^{-1}(\tfrac{1}{2} - \widehat{q} \mid x),\ \widehat{F}_T^{-1}(\tfrac{1}{2} + \widehat{q} \mid x)],$$

un intervalo entre dos cuantiles predictivos cuyo nivel corrige la calibración (Chernozhukov, Wüthrich y Zhu, 2021).

4.4. Clasificación

Con K etiquetas y probabilidades estimadas $\widehat{p}_1(x), \ldots, \widehat{p}_K(x)$ que suman uno:

Ejemplo 4.10 (probabilidad de la etiqueta, LAC)**.** $s_T(x, y) = 1 - \widehat{p}_y(x)$. Entonces

$$C(x) = \{y :\ 1 - \widehat{p}_y(x) \le \widehat{q}\} = \{y :\ \widehat{p}_y(x) \ge 1 - \widehat{q}\} :$$

entra toda etiqueta cuya probabilidad supera el umbral $1 - \widehat{q}$. Entre todos los conjuntos con cobertura marginal $1 - \alpha$, éste minimiza el tamaño esperado cuando las probabilidades son las verdaderas (Sadinle, Lei y Wasserman, 2019). Puede dar conjuntos vacíos: si ninguna etiqueta supera $1 - \widehat{q}$. Es el puntaje de las imágenes y del crédito.

Ejemplo 4.11 (masa acumulada, APS)**.** Se ordenan las etiquetas de mayor a menor probabilidad y

$$s_T(x, y) = \sum_{j:\ \widehat{p}_j(x) \ge \widehat{p}_y(x)} \widehat{p}_j(x),$$

la masa acumulada hasta llegar a y incluyéndola. Como el puntaje crece al bajar en el orden, el conjunto $\{y : s_T(x, y) \le \widehat{q}\}$ está formado por las etiquetas más probables mientras la masa acumulada no rebase $\widehat{q}$. Un caso ambiguo, con la masa repartida, recibe más etiquetas que con LAC; uno claro, menos. Romano, Sesia y Candès (2020) usan una versión con un desempate aleatorio que acerca la cobertura al nivel exacto.

Ejemplo 4.12 (vecino más cercano)**.** Sin probabilidades: con distancias en $\mathcal{X}$,

$$s_T(x, y) = \frac{\text{distancia de } x \text{ al vecino más cercano en } T \text{ con etiqueta } y}{\text{distancia de } x \text{ al vecino más cercano en } T \text{ con etiqueta distinta de } y}.$$

Una etiqueta es rara si x está lejos de los ejemplos de esa etiqueta y cerca de los de otras. Es el ejemplo clásico de Shafer y Vovk (2008).

Qué es "no sé". Con dos etiquetas, $C(x) = \{0, 1\}$ significa que el modelo no distingue lo suficiente para comprometerse. Con diez, $\{2, 3, 6, 8\}$ dice "es alguno de estos cuatro". El tamaño del conjunto es una medida honesta de la incertidumbre del modelo en ese caso.

5. Ordenar los puntajes de calibración

5.1. Estadísticos de orden y rangos

Dados los puntajes de calibración $S_1, \ldots, S_n$, sus *estadísticos de orden* son los mismos valores ordenados de menor a mayor:

$$S_{(1)} \le S_{(2)} \le \cdots \le S_{(n)}.$$

$S_{(1)}$ es el mínimo, $S_{(n)}$ el máximo, y $S_{(k)}$ es el k-ésimo valor más chico. Si hay valores repetidos, aparecen repetidos en la lista.

El *rango* del puntaje nuevo entre los $n+1$ puntajes es

$$R_{n+1} = 1 + \#\{i \le n : \ S_i < S_{n+1}\}.$$

Cuenta cuántos puntajes de calibración quedan estrictamente por debajo del nuevo y le suma uno. Si S_{n+1} es el más chico de todos, $R_{n+1} = 1$; si es el más grande, $R_{n+1} = n+1$.

Los huecos. Sin empates, los n puntajes de calibración parten la recta en $n+1$ huecos:

$$(-\infty, S_{(1)}),\ (S_{(1)}, S_{(2)}),\ \ldots,\ (S_{(n-1)}, S_{(n)}),\ (S_{(n)}, \infty).$$

El puntaje nuevo cae en exactamente uno de ellos, y el número de ese hueco (contando desde la izquierda) es su rango: si cae en el hueco r, hay exactamente $r-1$ puntajes de calibración por debajo. Con 19 puntajes hay 20 huecos.

5.2. El lema de conteo

Todo el método descansa en traducir "quedar por debajo del k-ésimo" a "tener rango a lo más k".

Lema 5.1 (conteo)**.** *Sea $1 \le k \le n$. Para todo número real s,*

$$s \le S_{(k)} \quad \Longleftrightarrow \quad \#\{i \le n : \ S_i < s\} \le k-1.$$

Demostración. ($\Rightarrow$) Si $s \le S_{(k)}$, todo $S_i < s$ cumple $S_i < S_{(k)}$. Los valores $S_{(k)}, S_{(k+1)}, \ldots, S_{(n)}$ son $n-k+1$ puntajes mayores o iguales que $S_{(k)}$, así que a lo más $n-(n-k+1) = k-1$ puntajes son estrictamente menores que $S_{(k)}$, y con mayor razón a lo más $k-1$ son menores que s.

($\Leftarrow$) Por contrapositiva: si $s > S_{(k)}$, entonces $S_{(1)} \le \cdots \le S_{(k)} < s$, y hay al menos k puntajes menores que s. ∎

Aplicado a $s = S_{n+1}$ y usando la definición del rango:

Corolario 5.2. *Si $1 \le k \le n$, $\{S_{n+1} \le S_{(k)}\} = \{R_{n+1} \le k\}$, con o sin empates.*

Es decir: *cubrir es caer en uno de los primeros k huecos.*

5.3. Por qué el cuantil lleva $n+1$

La forma natural de escribir el umbral es como un cuantil de la distribución empírica de los puntajes, *agregando un punto en $+\infty$ que representa al caso nuevo.*

Proposición 5.3. *Sea $\widehat{F}$ la distribución que pone masa $1/(n+1)$ en cada S_i y masa $1/(n+1)$ en $+\infty$. Su cuantil $1-\alpha$, $\inf\{s : \widehat{F}(s) \ge 1-\alpha\}$, es*

$$\widehat{q} = \begin{cases} S_{(k)}, & k \le n, \\ +\infty, & k = n+1, \end{cases} \qquad k = \lceil (n+1)(1-\alpha) \rceil.$$

Demostración. Para s finito, $\widehat{F}(s) = \#\{i : S_i \le s\}/(n+1)$. Así, $\widehat{F}(s) \ge 1-\alpha$ equivale a $\#\{i : S_i \le s\} \ge (n+1)(1-\alpha)$, y como el conteo es entero, a $\#\{i : S_i \le s\} \ge k$. El menor s que deja al menos k puntajes en $(-\infty, s]$ es $S_{(k)}$ si $k \le n$. Si $k = n+1$, ningún s finito acumula $n+1$ puntajes de calibración, y el ínfimo se alcanza en $+\infty$. ■

El punto en $+\infty$ es la manera de "hacer lugar" al caso nuevo, cuyo puntaje desconocemos: se supone lo peor. Con el cuantil ingenuo de los n puntajes, $k_{\text{ing}} = \lceil n(1-\alpha) \rceil$, se ignora ese lugar y la cobertura puede quedar por debajo de $1-\alpha$ (sección 9).

Por qué no se interpola. Los paquetes estadísticos suelen interpolar entre estadísticos de orden. Interpolar puede dar un umbral menor que $S_{(k)}$ y romper la cota inferior. La garantía es para el estadístico de orden exacto.

Empates. Si hay valores repetidos, el conjunto usa "$\le$": se incluye toda respuesta cuyo puntaje empate con $\widehat{q}$. Esa convención es conservadora: sólo puede aumentar la cobertura. La sección 8 lo prueba.

La pregunta que queda. Ya sabemos *qué* huecos cubren: los primeros k. Falta saber con qué probabilidad cae el caso nuevo en cada uno. Eso no lo dice el ordenamiento; lo dice el supuesto de la sección siguiente.

6. Intercambiabilidad: por qué los huecos son igual de probables

La sección anterior terminó con una pregunta: los n puntajes de calibración parten la recta en $n+1$ huecos y el caso nuevo cae en uno; cubrir es caer en los primeros k. ¿Con qué probabilidad cae en cada hueco? La respuesta es $1/(n+1)$ para todos, y el supuesto que la produce es la intercambiabilidad. La probabilidad es sobre la calibración y el caso nuevo juntos; no es la probabilidad de cada hueco para unos puntajes de calibración ya observados.

Definición 6.1. Un vector aleatorio $(Z_1, \dots, Z_N)$ es *intercambiable* si para toda permutación π de $\{1, \dots, N\}$

$$(Z_1, \dots, Z_N) \overset{d}{=} (Z_{\pi(1)}, \dots, Z_{\pi(N)}).$$

Equivalentemente, la ley conjunta es simétrica: ninguna posición es especial. En particular todas las Z_i tienen la misma marginal y todos los pares (Z_i, Z_j), $i \ne j$, la misma ley conjunta.

Proposición 6.2 (i.i.d. implica intercambiable)**.** *Si $Z_1, \dots, Z_N$ son i.i.d. con ley P, son intercambiables.*

Demostración. La ley conjunta es el producto $P \otimes \cdots \otimes P$. Para conjuntos medibles $A_1, \dots, A_N$, $\mathbb{P}(Z_{\pi(1)} \in A_1, \dots, Z_{\pi(N)} \in A_N) = \prod_i P(A_i) = \mathbb{P}(Z_1 \in A_1, \dots, Z_N \in A_N)$, porque el producto no depende del orden. Como los rectángulos generan la σ-álgebra producto, las dos leyes coinciden. ■

Proposición 6.3 (la urna)**.** *Sea una población finita de M unidades con valores $a_1, \dots, a_M$. Si se extraen $N \le M$ unidades al azar y sin reemplazo, los valores extraídos $(Z_1, \dots, Z_N)$ son intercambiables, pero no independientes.*

Demostración. Cada sucesión ordenada de N unidades distintas $(u_1, \dots, u_N)$ tiene probabilidad $\frac{1}{M} \cdot \frac{1}{M-1} \cdots \frac{1}{M-N+1} = \frac{(M-N)!}{M!}$, la misma para todas. Permutar las posiciones manda sucesiones de unidades distintas en sucesiones de unidades distintas de manera biyectiva, de modo que la ley de los

índices extraídos es invariante; también lo es la de sus valores. Para la dependencia: si los valores son distintos, $\mathbb{P}(Z_2 = a_1 \mid Z_1 = a_1) = 0 \neq 1/M$. ■

Ésta es la situación del conteo rápido *dentro de un estrato*: las casillas se sortean sin reemplazo. También la de 2012 en la sección 14.5: cada calibración es una muestra al azar de la población de casillas.

Lo que rompe la simetría. Series con tendencia; datos ordenados por hora de llegada; calibración de una población y prueba de otra. En todos ellos alguna posición es especial. La intercambiabilidad no se verifica mirando si los datos "se parecen"; se justifica por el mecanismo que los produce: un sorteo, una partición al azar.

Lema 6.4 (los puntajes heredan la simetría)**.** *Si $(Z_1, \ldots, Z_{n+1})$ es intercambiable condicionado a T y s_T es una función medible fijada con T, entonces $S_i = s_T(Z_i)$, $i = 1, \ldots, n+1$, es intercambiable condicionado a T.*

Demostración. Fijemos T y sea $g(z_1, \ldots, z_{n+1}) = (s_T(z_1), \ldots, s_T(z_{n+1}))$. Para una permutación π, sea $\sigma_\pi(z_1, \ldots, z_{n+1}) = (z_{\pi(1)}, \ldots, z_{\pi(n+1)})$. Aplicar s_T coordenada a coordenada y permutar conmutan: $g \circ \sigma_\pi = \sigma_\pi \circ g$. Entonces

$$\sigma_\pi(S) = \sigma_\pi(g(Z)) = g(\sigma_\pi(Z)) \overset{d}{=} g(Z) = S,$$

donde la igualdad en distribución usa que $\sigma_\pi(Z) \overset{d}{=} Z$ dado T y que g es una función fija dado T. ■

Por qué se separan los datos. El lema exige que s_T sea *la misma* función en todas las posiciones y que no dependa de las respuestas de calibración. Si se calibrara con residuos de entrenamiento, esos puntos ya fueron usados para ajustar y sus residuos tienden a ser más chicos que el del caso nuevo: la posición del caso nuevo sería especial. Lo mismo ocurre si se eligen el modelo, los hiperparámetros o el puntaje mirando la calibración.

7. El ejemplo de 19 puntajes, a fondo

7.1. El cálculo

Sea $n = 19$ y $\alpha = 0.10$. Primero el orden:

$$k = \lceil (19+1)(1-0.10) \rceil = \lceil 18 \rceil = 18 \leq 19,$$

así que el umbral es el decimoctavo puntaje más chico. Supongamos que los errores absolutos de calibración, ya ordenados, son

$$0.1,\ 0.2,\ 0.3,\ \ldots,\ 1.7,\ 1.8,\ 2.4,$$

es decir, $S_{(j)} = j/10$ para $j = 1, \ldots, 18$ y $S_{(19)} = 2.4$. Entonces $\widehat{q} = S_{(18)} = 1.8$. Con el puntaje $|y - \widehat{f}_T(x)|$ y una predicción $\widehat{f}_T(x) = 5$:

$$C(x) = [5 - 1.8,\ 5 + 1.8] = [3.2,\ 6.8].$$

El puntaje más grande, 2.4, no influye: el umbral ignora al peor de los 19. Si en lugar de 2.4 hubiera sido 240, el intervalo sería el mismo.

7.2. Dónde puede caer el caso nuevo

Sea $e = |Y_{n+1} - \widehat{f}_T(X_{n+1})|$ el error del caso nuevo. La tabla recorre los 20 huecos:

Hueco (rango)	Valores de e	Puntajes de calibración menores	¿$e \leq 1.8$?	¿Cubre?
1	$e < 0.1$	0	sí	sí
2	$0.1 < e < 0.2$	1	sí	sí
⋮	⋮	⋮	⋮	⋮
18	$1.7 < e < 1.8$	17	sí	sí
19	$1.8 < e < 2.4$	18	no	no
20	$e > 2.4$	19	no	no

Exactamente los primeros 18 huecos cubren, como dice el Corolario 5.2. Bajo intercambiabilidad, y sin empates, el caso nuevo tiene la misma probabilidad de caer en cualquiera de los 20 (Lema 8.1), así que cubre con probabilidad $18/20 = 0.90$.

7.3. Lo que el ejemplo no dice

El 90 % no es de esta calibración. La probabilidad 18/20 promedia sobre *todas* las calibraciones posibles y sobre el caso nuevo. Una vez que los 19 puntajes son estos, la cobertura del intervalo $[3.2, 6.8]$ es un número fijo: la probabilidad de que un error nuevo sea menor que 1.8. Si la distribución verdadera de los errores fuera, por ejemplo, exponencial con media 0.6, ese número sería $1 - e^{-1.8/0.6} = 0.950$; si la media fuera 1, sería $1 - e^{-1.8} = 0.835$. Al repetir la calibración, este número varía alrededor de 0.90 con ley Beta (sección 12).

Qué pasa al cambiar n o α.

- Con $n = 18$: $k = \lceil 19 \times 0.9 \rceil = \lceil 17.1 \rceil = 18$, el umbral es el máximo $S_{(18)}$ y la cobertura sin empates es $18/19 \approx 0.947$. No siempre se puede llegar exactamente a 0.90: los niveles alcanzables son múltiplos de $1/(n+1)$.
- Con $\alpha = 0.05$ y $n = 19$: $k = \lceil 19 \rceil = 19$, el umbral es el máximo 2.4 y el intervalo es $[2.6, 7.4]$, con cobertura $19/20 = 0.95$.
- Con $\alpha = 0.05$ y $n = 18$: $k = \lceil 18.05 \rceil = 19 > 18$, el umbral es $+\infty$ y el conjunto es toda la recta. Con 18 datos no se puede prometer 95 % de manera informativa.

El cuantil ingenuo. Con los mismos 19 puntajes, el cuantil 90 % "de libro" sin el $n + 1$ usa $\lceil 19 \times 0.9 \rceil = \lceil 17.1 \rceil = 18$: coincide por casualidad. Con $n = 10$, en cambio, el ingenuo usa $k = 9$ y cubre $9/11 \approx 0.818$, mientras que el corregido usa $k = 10$ y cubre $10/11 \approx 0.909$.

Empates en el ejemplo. Si dos puntajes valieran 1.8, por ejemplo $S_{(17)} = S_{(18)} = 1.8$, el umbral seguiría siendo 1.8 y el intervalo el mismo. Un error nuevo exactamente igual a 1.8 queda cubierto por la convención "$\leq$". Con errores continuos esto tiene probabilidad cero; con puntajes discretos (por ejemplo, árboles con pocas hojas) puede pasar y sólo aumenta la cobertura.

8. El teorema y su demostración

8.1. El algoritmo completo

1. Con el entrenamiento T: ajustar el modelo y fijar el puntaje s_T.
2. Con la calibración: calcular $S_i = s_T(X_i, Y_i)$, $i = 1, \ldots, n$, y ordenarlos.
3. Con $k = \lceil (n+1)(1-\alpha) \rceil$: tomar $\widehat{q} = S_{(k)}$ si $k \leq n$, y $\widehat{q} = +\infty$ si $k = n+1$.
4. Para el caso nuevo: $C(X_{n+1}) = \{y : \ s_T(X_{n+1}, y) \leq \widehat{q}\}$.

8.2. El rango es uniforme

Para cada posición $j \in \{1, \ldots, n+1\}$ definimos su rango entre los $n+1$ puntajes,

$$R_j = 1 + \#\{i \neq j : \ S_i < S_j\},$$

de modo que R_{n+1} es el rango del caso nuevo de la sección 5.

Lema 8.1 (rango uniforme)**.** *Si $(S_1, \ldots, S_{n+1})$ es intercambiable dado T y los puntajes, con valores en un conjunto con orden total (números reales o pares en orden lexicográfico), son distintos casi seguramente, entonces para cada j*

$$\mathbb{P}(R_j = r \mid T) = \frac{1}{n+1}, \qquad r = 1, \ldots, n+1.$$

Demostración. Paso 1: los rangos son una permutación. Si los $n+1$ puntajes son distintos, ordenarlos asigna a cada uno una posición distinta del 1 al $n+1$, y esa posición es exactamente R_j. Así, $(R_1, \ldots, R_{n+1})$ es una permutación de $\{1, \ldots, n+1\}$, y para cada r

$$\sum_{j=1}^{n+1} \mathbf{1}\{R_j = r\} = 1.$$

Paso 2: todas las posiciones tienen la misma ley de rango. Fijemos j y sea π la transposición que intercambia j y $n+1$. El rango es una función de todo el vector, $R_j = \rho_j(S_1, \ldots, S_{n+1})$, y permutar el vector intercambia los papeles: $\rho_{n+1}(S_{\pi(1)}, \ldots, S_{\pi(n+1)}) = \rho_j(S_1, \ldots, S_{n+1})$. Por intercambiabilidad $(S_{\pi(1)}, \ldots, S_{\pi(n+1)}) \overset{d}{=} (S_1, \ldots, S_{n+1})$ dado T, así que

$$\mathbb{P}(R_{n+1} = r \mid T) = \mathbb{P}\big(\rho_{n+1}(S_\pi) = r \mid T\big) = \mathbb{P}(\rho_j(S) = r \mid T) = \mathbb{P}(R_j = r \mid T).$$

Paso 3: cada una vale $1/(n+1)$. Tomando esperanza condicional en el paso 1, $\sum_j \mathbb{P}(R_j = r \mid T) = 1$. Los $n+1$ sumandos son iguales por el paso 2, así que cada uno vale $1/(n+1)$. ∎

8.3. El teorema

Teorema 8.2 (cobertura de split conformal)**.** *Si los puntajes $(S_1, \dots, S_{n+1})$ son intercambiables dado T, entonces*

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid T\} \;\geq\; \frac{k}{n+1} \;\geq\; 1-\alpha.$$

Si además son distintos casi seguramente, la primera desigualdad es una igualdad y

$$1-\alpha \;\leq\; \mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid T\} \;<\; 1-\alpha+\frac{1}{n+1}.$$

Las mismas cotas valen sin condicionar a T.

Demostración sin empates. Caso $k = n+1$. Entonces $\widehat{q} = +\infty$, el conjunto es todo el espacio y la cobertura es $1 = k/(n+1)$.

Caso $k \leq n$. Por definición del conjunto y del umbral, $\{Y_{n+1} \in C(X_{n+1})\} = \{s_T(X_{n+1}, Y_{n+1}) \leq \widehat{q}\} = \{S_{n+1} \leq S_{(k)}\}$, y por el Corolario 5.2 esto es $\{R_{n+1} \leq k\}$. Por el Lema 8.1,

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid T\} = \sum_{r=1}^{k} \mathbb{P}(R_{n+1} = r \mid T) = \frac{k}{n+1}.$$

Las cotas. Como k es el menor entero mayor o igual que $(n+1)(1-\alpha)$,

$$(n+1)(1-\alpha) \;\leq\; k \;<\; (n+1)(1-\alpha)+1.$$

Dividiendo entre $n+1$: $1-\alpha \leq k/(n+1) < 1-\alpha+1/(n+1)$.

Sin condicionar. Por la ley de la esperanza total, $\mathbb{P}\{Y_{n+1} \in C(X_{n+1})\} = \mathbb{E}\big[\mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid T\}\big]$, y las cotas, que no dependen de T, pasan al promedio. ∎

Demostración de la cota inferior con empates. Si $k = n+1$ no hay nada que probar. Sea $k \leq n$. Tomemos $U_1, \dots, U_{n+1}$ i.i.d. uniformes en $(0,1)$, independientes de los datos y de T, y ordenemos los pares (S_i, U_i) lexicográficamente: primero por puntaje y, si empatan, por U_i. Los pares son intercambiables dado T (el vector de pares es la imagen del vector intercambiable $((Z_i, U_i))_i$) y distintos casi seguramente, porque dos U coinciden con probabilidad cero. Su rango

$$R^*_{n+1} = 1 + \#\{i \leq n :\; (S_i, U_i) < (S_{n+1}, U_{n+1})\}$$

es uniforme por el Lema 8.1. Si $S_i < S_{n+1}$ entonces $(S_i, U_i) < (S_{n+1}, U_{n+1})$, así que

$$R_{n+1} = 1 + \#\{i \leq n :\; S_i < S_{n+1}\} \;\leq\; R^*_{n+1}.$$

Por tanto $\{R^*_{n+1} \leq k\} \subseteq \{R_{n+1} \leq k\} = \{S_{n+1} \leq S_{(k)}\}$, la última igualdad por el Corolario 5.2, que vale con empates. Así

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid T\} \;\geq\; \mathbb{P}(R^*_{n+1} \leq k \mid T) = \frac{k}{n+1} \;\geq\; 1-\alpha.$$

El desempate es sólo un artificio de la prueba: el conjunto que se usa en la práctica no cambia. ∎

Por qué con empates no hay cota superior. La regla "$\leq$" incluye los empates con el umbral, lo que sólo puede aumentar la cobertura. En el extremo, si los $n+1$ puntajes son iguales casi seguramente, el conjunto cubre siempre. Un procedimiento que use explícitamente el desempate al predecir recupera la igualdad $k/(n+1)$, a costa de aleatorizar la inclusión de etiquetas.

Lo que la prueba no usó. Que el modelo sea correcto, normalidad, independencia, ni n grande. Sólo intercambiabilidad de los puntajes. Y la cota superior dice que la garantía no es holgada: sin empates el procedimiento cubre entre $1-\alpha$ y $1-\alpha+1/(n+1)$.

Exactitud. "Exacto en muestra finita" significa que la garantía no depende de un límite. La igualdad con $1-\alpha$ requiere además que $(n+1)(1-\alpha)$ sea entero; en otro caso la cobertura sin empates es $k/(n+1)$, ligeramente mayor.

9. Muestra finita

9.1. El cuantil ingenuo cubre de menos

Con el cuantil ingenuo $k_{\text{ing}} = \lceil n(1-\alpha) \rceil$, el mismo argumento da cobertura sin empates $k_{\text{ing}}/(n+1)$:

n	k_{ing}	Cobertura ingenua	k	Cobertura corregida
10	9	$9/11 = 81.82\,\%$	10	$10/11 = 90.91\,\%$
19	18	$18/20 = 90\,\%$	18	$18/20 = 90\,\%$
50	45	$45/51 = 88.24\,\%$	46	$46/51 = 90.20\,\%$
100	90	$90/101 = 89.11\,\%$	91	$91/101 = 90.10\,\%$

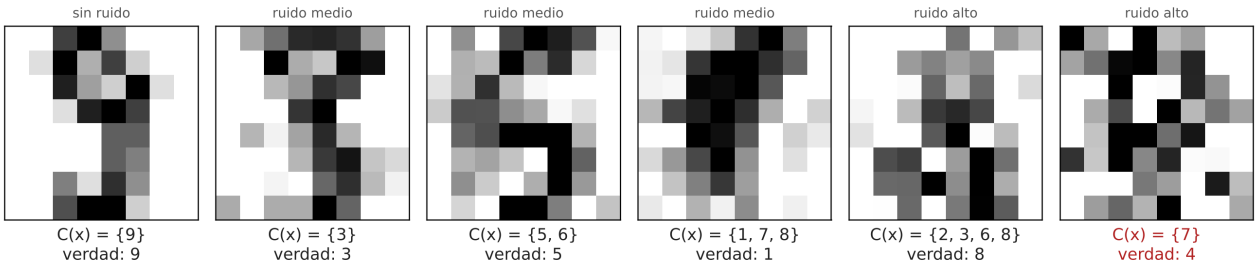
9.2. Tamaño mínimo de calibración

Proposición 9.1. *El umbral es finito ($k \leq n$) si y sólo si $n \geq 1/\alpha - 1$.*

Demostración. Para n entero, $\lceil x \rceil \leq n \iff x \leq n$. Así $k \leq n \iff (n+1)(1-\alpha) \leq n \iff n+1-\alpha(n+1) \leq n \iff 1 \leq \alpha(n+1) \iff n \geq 1/\alpha - 1$. ■

Con $\alpha = 0.10$ se necesitan al menos 9 datos; con $\alpha = 0.05$, 19; con $\alpha = 0.01$, 99. La condición sólo evita el conjunto trivial; no asegura que el conjunto sea útil. Además, sin empates sólo son alcanzables las coberturas $1/(n+1), 2/(n+1), \ldots, 1$.

10. Volvamos a los dígitos: tamaño y grupos



En la partición mostrada el umbral fue $\widehat{q} = 0.84$: entra al conjunto toda etiqueta con probabilidad estimada de al menos 0.16. Una imagen clara recibe una sola etiqueta; una borrosa, varias. El caso en rojo es un fallo: el modelo le dio 0.56 a un 7 y era un 4. Fallar en 10 % de los casos es parte del contrato.

	Todas	Sin ruido	Ruido medio	Ruido alto
Cobertura	89.9 %	97.1 %	94.2 %	78.6 %
Tamaño medio del conjunto	1.40	1.23	1.36	1.60
Conjuntos de una etiqueta	66.0 %	79.7 %	68.7 %	49.8 %
Exactitud del modelo	80.9 %	92.7 %	86.4 %	63.6 %

Medias de 100 particiones; el error Monte Carlo de la cobertura global es 0.17 puntos. En promedio $\widehat{q} = 0.82$; los conjuntos vacíos aparecen en 0.08 % de los casos.

Lectura. En términos de los tres deseables de la sección 1:

1. *Cobertura*: la global es la prometida, aunque el modelo sólo acierta 81 % de las veces. El conjunto compensa con tamaño lo que el modelo no sabe.
2. *Tamaño*: 1.4 etiquetas en promedio, de diez posibles.
3. *Adaptatividad*: más ruido, más etiquetas. Pero la cobertura no es 90 % en cada grupo: las imágenes limpias se cubren de más (97 %) y las más borrosas de menos (79 %). El promedio esconde la diferencia; es el tema de la sección siguiente.

11. Cobertura marginal y cobertura condicional

11.1. Las dos garantías

La garantía del Teorema 8.2 es *marginal*:

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1})\} \geq 1 - \alpha,$$

un promedio sobre todos los casos. La garantía deseable sería *condicional*:

$$\mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid X_{n+1} = x\} \geq 1 - \alpha \quad \text{para casi todo } x.$$

La condicional implica la marginal (promediando sobre x), pero no al revés. Con dos grupos:

	Sin garantía	Marginal	Condicional
Grupo 1 (80 % de los casos)	75 %	100 %	90 %
Grupo 2 (20 % de los casos)	60 %	50 %	90 %
Global	72 %	90 %	90 %

La columna del centro cumple la garantía marginal porque $0.8 \times 1 + 0.2 \times 0.5 = 0.90$, aunque un grupo se cubra a la mitad. El fenómeno aparece en los tres ejemplos: las imágenes más borrosas se cubren al 79 %, los incumplidores al 56–58 % y las casillas rurales alrededor del 75 %.

Lo que no se puede pedir. Para una respuesta real, si un procedimiento garantiza cobertura condicional para *toda* distribución, entonces para casi todo punto x (respecto de la distribución de X) que no sea un átomo, la longitud esperada del conjunto es infinita (Vovk, 2012; Lei y Wasserman, 2014; Foygel Barber et al., 2021). La intuición: con X continua no hay datos en x exactamente y, sin supuestos sobre cómo cambia la distribución de Y entre vecinos, no se puede aprender nada de x a partir de ellos. Para etiquetas o proporciones, con soporte acotado, no se traslada literalmente "longitud infinita": ahí siempre existe el conjunto universal.

11.2. Lo que sí se puede: medir y calibrar por grupo

Medir. Aunque no se pueda garantizar, la cobertura condicional se puede *diagnosticar* estratificando los casos de prueba en grupos con suficientes datos y midiendo la cobertura en cada uno (Angelopoulos y Bates, 2023):

- *Por clase*: cobertura entre los que tienen $Y = y$. En crédito revela que los incumplidores quedan mal cubiertos (sección 13).
- *Por grupo de covariables*: nivel de ruido en los dígitos, tipo de sección en las casillas.
- *Por tamaño del conjunto*: si los conjuntos chicos (casos fáciles) cubren mucho y los grandes (casos difíciles) poco, el procedimiento "se rinde" en los casos difíciles. En los dígitos, con el puntaje LAC:

Tamaño del conjunto	1	2	3 o más
Cobertura	92.1 %	86.0 %	87.5 %

  Una diferencia moderada: LAC minimiza el tamaño medio, pero no es el más adaptativo. Un puntaje como APS (sección 4) busca emparejar estas coberturas.

Calibrar. Cobertura dentro de grupos fijados de antemano, calibrando por separado en cada uno. Se demuestra y se aplica al crédito en la sección 13.5.

12. Variación entre calibraciones: la distribución Beta

12.1. Cobertura de una calibración fija

Esta sección tiene dos usos. Teórico: describe cuánto puede alejarse del nominal una calibración concreta. Práctico: como la distribución de la cobertura es conocida, sirve para revisar una implementación. Se repite muchas veces la partición en calibración y prueba, se calcula la cobertura empírica en cada repetición y se compara el histograma con la curva teórica; si no coinciden, hay un error (Angelopoulos y Bates, 2023). La sección 14.5 hace exactamente eso con datos reales.

La garantía promedia sobre calibraciones. Pero en la práctica se calibra una sola vez. Definimos la cobertura de *esa* calibración:

$$Q(D_{\text{cal}}; T) = \mathbb{P}\{Y_{n+1} \in C(X_{n+1}) \mid D_{\text{cal}}, T\}.$$

Una vez fijados D_{cal} y T, Q es un número. El teorema dice que $\mathbb{E}(Q \mid T) \geq 1 - \alpha$. ¿Cuánto varía Q de una calibración a otra?

Necesitamos un supuesto más fuerte que la intercambiabilidad: dado T, los puntajes de calibración y del caso nuevo son i.i.d. con una función de distribución F continua.

Lema 12.1 (transformación integral de probabilidad)**.** *Si S tiene función de distribución continua F, entonces $U = F(S)$ es uniforme en $(0,1)$.*

Demostración. Sea $u \in (0,1)$ y $s^* = \sup\{s : \ F(s) \le u\}$. Por continuidad, $F(s^*) = u$. Si $S \le s^*$, entonces $F(S) \le F(s^*) = u$ porque F es no decreciente; si $S > s^*$, entonces $F(S) > u$ por la definición del supremo. Así $\{F(S) \le u\} = \{S \le s^*\}$ y $\mathbb{P}(F(S) \le u) = F(s^*) = u$. ■

Teorema 12.2 (la cobertura de una calibración es Beta)**.** *Si, dado T, los puntajes $S_1, \dots, S_{n+1}$ son i.i.d. con distribución continua F y $1 \le k \le n$, entonces*

$$Q(D_{\text{cal}}; T) = F(S_{(k)}) \qquad y \qquad Q \mid T \ \sim \ \text{Beta}(k,\ n+1-k).$$

Demostración. Paso 1: $Q = F(S_{(k)})$. Dados D_{cal} y T, el umbral $S_{(k)}$ es un número fijo y el puntaje nuevo S_{n+1} es independiente de la calibración con distribución F. Por tanto $Q = \mathbb{P}(S_{n+1} \le S_{(k)} \mid D_{\text{cal}}, T) = F(S_{(k)})$.

Paso 2: $F(S_{(k)}) = U_{(k)}$. Sean $U_i = F(S_i)$, uniformes i.i.d. por el Lema 12.1. Una función no decreciente preserva el orden: si $S_i \le S_j$ entonces $U_i \le U_j$. Por tanto el k-ésimo menor de los U_i es F aplicada al k-ésimo menor de los S_i: $U_{(k)} = F(S_{(k)})$.

Paso 3: la distribución de $U_{(k)}$. Para $0 < u < 1$, el evento $\{U_{(k)} \le u\}$ ocurre si y sólo si al menos k de las n uniformes caen en $[0,u]$. El número de uniformes en $[0,u]$ es binomial(n,u), así que

$$G(u) := \mathbb{P}(U_{(k)} \le u) = \sum_{j=k}^{n} \binom{n}{j} u^j (1-u)^{n-j}.$$

Paso 4: la densidad. Derivando término a término,

$$G'(u) = \sum_{j=k}^{n} \binom{n}{j} \Big[j\, u^{j-1}(1-u)^{n-j} - (n-j)\, u^j (1-u)^{n-j-1} \Big].$$

Con las identidades $j\binom{n}{j} = n\binom{n-1}{j-1}$ y $(n-j)\binom{n}{j} = n\binom{n-1}{j}$, y escribiendo $a_j = \binom{n-1}{j} u^j (1-u)^{n-1-j}$ (con $a_n = 0$), cada sumando es $n(a_{j-1} - a_j)$. La suma es telescópica:

$$G'(u) = n \sum_{j=k}^{n} (a_{j-1} - a_j) = n\,(a_{k-1} - a_n) = n \binom{n-1}{k-1} u^{k-1}(1-u)^{n-k},$$

es decir, $G'(u) = \dfrac{n!}{(k-1)!\,(n-k)!}\, u^{k-1}(1-u)^{n-k}$. Como $B(k, n+1-k) = \Gamma(k)\Gamma(n+1-k)/\Gamma(n+1) = (k-1)!(n-k)!/n!$, ésta es la densidad Beta$(k, n+1-k)$. ■

Si $k = n+1$, el conjunto es universal y $Q = 1$; no hay una Beta con segundo parámetro cero.

Momentos. Para una Beta(a, b), la media es $a/(a+b)$ y la varianza $ab/\{(a+b)^2(a+b+1)\}$. Con $a = k$ y $b = n+1-k$:

$$\mathbb{E}(Q \mid T) = \frac{k}{n+1}, \qquad \mathrm{Var}(Q \mid T) = \frac{k(n+1-k)}{(n+1)^2(n+2)}.$$

La media reproduce el Teorema 8.2. La desviación estándar decrece como $1/\sqrt{n}$:

n	k	DE de Q	$\mathbb{P}(Q < 0.85 \mid T)$	$\mathbb{P}(Q < 0.88 \mid T)$
19	18	0.0655	0.198	0.317
99	90	0.0299	0.060	0.236
199	180	0.0212	0.016	0.170
999	900	0.0095	< 0.001	0.021

Con $n = 19$, una de cada cinco calibraciones cubre menos de 85 %. La Beta requiere puntajes i.i.d. continuos: no se deduce sólo de intercambiabilidad.

Cobertura observada en prueba. Si se evalúan m casos nuevos i.i.d., el número cubierto dado D_{cal}, T es binomial(m, Q); al repetir la calibración su ley es beta-binomial. La proporción observada suma el ruido de evaluación a la variación de Q.

12.2. Garantía sobre la calibración (tipo PAC)

Si se quiere que, con probabilidad al menos $1-\delta$ sobre la calibración, *esa* calibración cubra al menos $1-\alpha$,

$$\mathbb{P}\{Q(D_{\mathrm{cal}}; T) \geq 1-\alpha \mid T\} \geq 1-\delta,$$

basta elegir el menor $k \leq n$ tal que $\mathbb{P}\{\mathrm{Beta}(k, n+1-k) < 1-\alpha\} \leq \delta$. Por el paso 3 de la prueba, esa probabilidad es

$$\mathbb{P}\{U_{(k)} < 1-\alpha\} = \sum_{j=k}^{n} \binom{n}{j} (1-\alpha)^j \alpha^{n-j}.$$

Con $\alpha = \delta = 0.10$: para $n = 99$ se usa $k = 94$ en lugar de 90; para $n = 999$, $k = 912$ en lugar de 900. Es un umbral más conservador a cambio de una garantía por corrida (Vovk, 2012).

13. Crédito

13.1. La referencia clásica: oráculo y plug-in

En crédito $Y = 1$ representa incumplimiento y $p(x) = \mathbb{P}(Y = 1 \mid X = x)$.

Proposición 13.1. *Si se conoce $p(x)$ y $\alpha < 1/2$, el conjunto*

$$C_{\mathrm{or}}(x) = \begin{cases} \{0\}, & p(x) \leq \alpha, \\ \{1\}, & p(x) \geq 1-\alpha, \\ \{0,1\}, & \textit{en otro caso} \end{cases}$$

cumple $\mathbb{P}\{Y \in C_{\mathrm{or}}(X) \mid X = x\} \geq 1-\alpha$ para cada x, y es el conjunto de menor tamaño con esa propiedad.

Demostración. Si $p(x) \le \alpha$, el conjunto $\{0\}$ cubre con probabilidad $1 - p(x) \ge 1 - \alpha$. Si $p(x) \ge 1 - \alpha$, $\{1\}$ cubre con probabilidad $p(x) \ge 1 - \alpha$. En otro caso $\{0, 1\}$ cubre con probabilidad uno. Para la minimalidad: un conjunto de una etiqueta cubre con probabilidad $p(x)$ o $1 - p(x)$, y en el caso intermedio ambas son menores que $1 - \alpha$, así que se necesitan las dos. ■

Reemplazar p por una estimación $\widehat{p}_T$ produce un *comparador plug-in* sin la garantía. Si $p(x) = 0.15$ y $\widehat{p}_T(x) = 0.09$, con $\alpha = 0.10$ el conjunto es $\{0\}$ y cubre a ese x con probabilidad 0.85.

Qué aporta un IC de Wald. Puede emitirse $\{0\}$ sólo si todo un intervalo de confianza de $p(x)$ queda por debajo de α. Esto aumenta la abstención, pero no demuestra cobertura predictiva de 90 %: si el IC al 95 % fuera exacto para cada x, el argumento que combina ambos eventos sólo da $(1 - 0.05)(1 - 0.10) = 0.855$. Además, los IC de Wald son aproximaciones asintóticas.

13.2. Datos y diseño

Base *Default of Credit Card Clients* de UCI (Yeh y Lien, 2009): 30,000 clientes de Taiwán, 22.1 % en incumplimiento al mes siguiente. $Y = 1$ es incumplimiento. Veinte particiones aleatorias 60/20/20; preprocesamiento ajustado sólo con entrenamiento; $\alpha = 0.10$. Se comparan una regresión logística sin penalizar con todas las variables y un *HistGradientBoosting*.

13.3. El conjunto con dos clases

Con el puntaje LAC y $\widehat{p}(x) = \widehat{p}_1(x)$, como $\widehat{p}_0 = 1 - \widehat{p}$,

$$0 \in C(x) \iff 1 - \widehat{p}_0(x) \le \widehat{q} \iff \widehat{p}(x) \le \widehat{q}, \qquad 1 \in C(x) \iff 1 - \widehat{p}(x) \le \widehat{q} \iff \widehat{p}(x) \ge 1 - \widehat{q}.$$

Si $\widehat{q} \ge 1/2$, entonces $1 - \widehat{q} \le \widehat{q}$ y

$$C(x) = \begin{cases} \{0\}, & \widehat{p}(x) < 1 - \widehat{q}, \\ \{0, 1\}, & 1 - \widehat{q} \le \widehat{p}(x) \le \widehat{q}, \\ \{1\}, & \widehat{p}(x) > \widehat{q}. \end{cases}$$

Si $\widehat{q} < 1/2$, para $\widehat{q} < \widehat{p}(x) < 1 - \widehat{q}$ ninguna etiqueta entra: conjunto vacío. Comparado con el oráculo de la sección 13, los cortes 0.1 y 0.9 se sustituyen por $1 - \widehat{q}$ y $\widehat{q}$, que salen de la calibración.

13.4. Resultados marginales

Método	Cobertura	{paga}	{incumple}	Ambas	Cubre paga	Cubre incumple
Logística plug-in	97.8 %	19.2 %	0.2 %	80.6 %	99.9 %	90.5 %
Logística plug-in + IC de Wald	98.5 %	13.7 %	0.1 %	86.2 %	99.9 %	93.3 %
Logística conforme	90.0 %	72.9 %	0.8 %	26.3 %	99.7 %	56.1 %
Boosting plug-in	98.0 %	28.8 %	0.0 %	71.2 %	100.0 %	91.2 %
Boosting conforme	90.0 %	75.0 %	3.0 %	22.0 %	99.2 %	57.9 %

AUC: 0.726 (logística) y 0.783 (boosting). Umbral medio: 0.747 y 0.735. Error Monte Carlo de la cobertura conforme: 0.16 y 0.13 puntos. No hubo conjuntos vacíos.

Dos comparaciones. (1) Mismo modelo, distinto conjunto: el plug-in promete 90 % para cada cliente *si el modelo fuera correcto*; como casi todos tienen $\widehat{p}$ entre 0.1 y 0.9, a 81 % le dice "ambas". Conformal sólo promete 90 % en promedio y usa ese margen: con $\widehat{q} \approx 0.75$ da {paga} a quien tiene $\widehat{p} < 0.25$. (2) Mismo puntaje, distinto modelo: el boosting tiene la misma garantía y entrega más conjuntos de una etiqueta. La utilidad depende del modelo; la garantía, no.

El límite. Conformal cubre 99 % a quienes pagan y sólo 56–58 % a quienes incumplen. Es el mismo fenómeno de las imágenes borrosas: un grupo minoritario y difícil queda por debajo y el promedio no lo muestra.

13.5. Introducción a la cobertura por clase

La idea es calibrar *por separado* con los puntajes de cada clase. Para cada etiqueta y, sea $I_y = \{i \leq n : \ Y_i = y\}$ el conjunto de índices de calibración con esa clase, $n_y = |I_y|$, y

$$k_y = \lceil (n_y + 1)(1 - \alpha) \rceil, \qquad \widehat{q}_y = \begin{cases} k_y\text{-ésimo menor de } \{S_i : i \in I_y\}, & k_y \leq n_y, \\ +\infty, & k_y = n_y + 1, \end{cases}$$

$$C^{\mathrm{M}}(x) = \{y : \ s_T(x, y) \leq \widehat{q}_y\}.$$

Cada etiqueta candidata se prueba contra el umbral de su propia clase. No hace falta conocer la clase verdadera del caso nuevo.

Teorema 13.2 (cobertura por clase)**.** *Si, dado T, los datos de calibración y el caso nuevo son i.i.d., entonces para cada clase y con $\mathbb{P}(Y = y) > 0$,*

$$\mathbb{P}\{Y_{n+1} \in C^{\mathrm{M}}(X_{n+1}) \mid Y_{n+1} = y, \ T\} \ \geq \ 1 - \alpha.$$

Demostración. Fijemos y y condicionemos en $Y_{n+1} = y$ y en el conjunto I_y. Dado esto, las observaciones $\{Z_i : i \in I_y\}$ y Z_{n+1} son i.i.d. con la ley de (X, Y) condicionada a $Y = y$: la independencia de los datos hace que condicionar en las etiquetas de unas no altere la ley de las otras. Sus puntajes $S_i = s_T(X_i, y)$, $i \in I_y$, y $S_{n+1} = s_T(X_{n+1}, y)$ son entonces i.i.d. y, en particular, intercambiables. El evento de cobertura es

$$\{Y_{n+1} \in C^{\mathrm{M}}(X_{n+1})\} = \{s_T(X_{n+1}, y) \leq \widehat{q}_y\} = \{S_{n+1} \leq \widehat{q}_y\},$$

que es exactamente el evento del Teorema 8.2 aplicado a una calibración de tamaño n_y. Por ese teorema, su probabilidad condicional es al menos $1 - \alpha$ (si n_y es tan chico que $k_y = n_y + 1$, el umbral es infinito y la cobertura es uno). Promediando sobre I_y se obtiene la afirmación. ■

Lo que cuesta. Cada clase necesita su propia calibración suficiente, y los conjuntos crecen. En crédito, con las mismas 20 particiones:

Modelo	Calibración	Cobertura	Cubre paga	Cubre incumple	{paga}	{incumple}	Ambas
Logística	marginal	90.0 %	99.7 %	56.1 %	72.9 %	0.8 %	26.3 %
	por clase	90.3 %	90.3 %	90.5 %	19.4 %	17.9 %	62.7 %
Boosting	marginal	90.0 %	99.2 %	57.9 %	75.0 %	3.0 %	22.0 %
	por clase	90.3 %	90.3 %	90.2 %	30.9 %	18.5 %	50.6 %

Los umbrales por clase quedaron en promedio en $\widehat{q}_0 \approx 0.30$ y $\widehat{q}_1 \approx 0.90$ para la logística, y 0.34 y 0.90 para el boosting. La garantía por clase se cumple y se paga con más "no sé"; el mejor modelo paga menos ese costo (51 % contra 63 %). En imágenes, el análogo sería calibrar por nivel de ruido; en las casillas, por tipo de sección. Cuando los grupos dependen de x (y no de la etiqueta), el mismo argumento funciona condicionando en el grupo del caso nuevo, que sí se conoce.

13.6. Complemento: abstención y error entre decisiones

Supongamos que sólo se decide automáticamente cuando el conjunto tiene una etiqueta, y que los conjuntos $\{\text{paga}, \text{incumple}\}$ pasan a revisión humana.

Contar de 100 en 100. Con la logística conforme, de cada 100 clientes, 74 reciben una sola etiqueta y 26 reciben las dos. Un conjunto con las dos etiquetas siempre contiene la respuesta correcta, así que ahí no hay errores. Los 10 fallos que permite la cobertura de 90 % caen, entonces, entre los 74 casos decididos, y el error entre las decisiones automáticas es $10/74 \approx 13.5\,\%$, no 10 %. La proposición siguiente lo hace general.

Sea $A = \{|C(X_{n+1})| = 1\}$; en A la decisión es la única etiqueta del conjunto.

Proposición 13.3. *Si la cobertura es al menos* $1-\alpha$ *y* $\mathbb{P}(A) > 0$*,*

$$\mathbb{P}(\textit{error} \cap A) \le \alpha, \qquad \mathbb{P}(\textit{error} \mid A) \le \min\{1, \alpha/\mathbb{P}(A)\}.$$

Si además nunca hay conjuntos vacíos y hay dos clases, $\mathbb{P}(\textit{error} \cap A) = 1 - \textit{cobertura}$*.*

Demostración. En A, equivocarse significa que la verdadera etiqueta no es la única del conjunto, es decir, $Y_{n+1} \notin C(X_{n+1})$. Así $\{\text{error}\} \cap A \subseteq \{Y_{n+1} \notin C(X_{n+1})\}$, cuya probabilidad es a lo más α. Dividir entre $\mathbb{P}(A)$ da la segunda cota. Si no hay vacíos y hay dos clases, los conjuntos que no son de una etiqueta son $\{0, 1\}$, que siempre cubren; entonces todo fallo de cobertura ocurre en A y la contención es una igualdad. ■

	Logística conforme	Boosting conforme
Una sola etiqueta, $\widehat{\mathbb{P}}(A)$	73.7 %	78.0 %
Error entre decisiones	13.5 %	12.9 %
Cota $\alpha/\widehat{\mathbb{P}}(A)$	13.6 %	12.8 %

Una cobertura de 90 % no es 90 % de acierto entre las decisiones automáticas: el error selectivo puede llegar a $\alpha/\mathbb{P}(A)$. Aquí casi se alcanza porque no hay vacíos. El boosting queda 0.03 puntos sobre la cota estimada porque su cobertura observada fue 89.97 %: la cota es poblacional y las cifras son estimaciones, y la diferencia es mucho menor que su error Monte Carlo.

Alcance. Una partición aleatoria de una base fija da intercambiabilidad entre calibración y prueba dentro de esa base. No dice nada sobre otro periodo u otra población.

14. Elecciones 2012: el caso principal

14.1. El problema

En un conteo rápido se *sortea* una muestra de casillas. La pregunta conforme es local: ¿qué proporción de votos tendrá PRI-PVEM en una casilla que no quedó en la muestra? La población son las 143,100

casillas de la elección presidencial de 2012 con votos registrados (paquete `quickcountmx`, objeto `nal_2012`).

Intercambiabilidad por diseño. Si la muestra es un sorteo aleatorio simple, una casilla muestreada y una no muestreada al azar son intercambiables (Proposición 6.3): la garantía no depende de un supuesto sobre los votantes; la produce el sorteo.

14.2. Procedimiento

1. Sortear 7,500 casillas, el tamaño de un conteo rápido.
2. Con 3,750 de ellas, ajustar un boosting de regresión con covariables de la casilla (entidad, tipo de sección, ruralidad, tamaño de la sección, tipo de casilla y lista nominal), sin votos.
3. Con las otras 3,750, calibrar con el puntaje $|y - \widehat{f}_T(x)|$ y $\alpha = 0.10$. En promedio, la calibración tiene 2,491 casillas urbanas, 422 mixtas y 804 rurales (la suma es menor que 3,750 porque algunas casillas no tienen tipo de sección asignado; esas sólo entran al umbral único).
4. Evaluar en las 135,600 casillas no muestreadas (143,100 − 7,500).

Se repite con 20 sorteos distintos; las cifras son medias de los 20.

14.3. Resultados

	Un solo umbral		Un umbral por tipo de sección	
	Cobertura	Ancho	Cobertura	Ancho
Urbanas	94.8 %	0.32	90.0 %	0.26
Mixtas	89.0 %	0.32	90.3 %	0.34
Rurales	75.6 %	0.32	90.0 %	0.47
Todas	90.0 %	0.32	90.0 %	0.32

El ancho está en proporción de votos (0.32 equivale a ±16 puntos porcentuales). Errores Monte Carlo de la cobertura entre 0.1 y 0.3 puntos.

Lectura. Con un solo umbral, la cobertura global es exactamente la prometida, como dice el Teorema 8.2: el sorteo produce la intercambiabilidad. Pero las rurales, más difíciles de predecir, se cubren 76 % y las urbanas 95 %: marginal no es por grupo (sección 11). Con un umbral por tipo de sección (el mismo argumento del Teorema 13.2, con el grupo definido por x en lugar de la etiqueta), cada grupo recupera su 90 %. El intervalo se ensancha en las rurales y se angosta en las urbanas, y el ancho promedio casi no cambia: la incertidumbre se redistribuye a donde está.

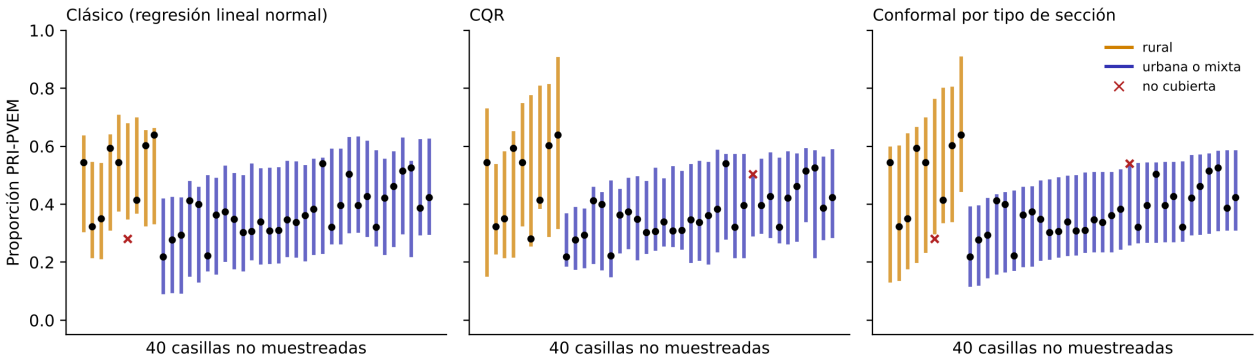
14.4. Cómo se ven distintos intervalos de predicción

Con los mismos 20 sorteos (3,750 casillas para entrenar, 3,750 para calibrar, 135,600 para evaluar) se comparan cinco intervalos al 90 %:

1. **Clásico (lineal normal).** Mínimos cuadrados con las mismas covariables (codificadas con indicadoras) ajustado con las 7,500 casillas de la muestra, y el intervalo $\widehat{f}_T(x) \pm t_{0.95,\, m-d}\, \hat{\sigma} \sqrt{1 + h(x)}$ de la sección 2. Su garantía viene de la normalidad, la linealidad y la varianza constante.

2. **Cuantiles sin calibrar.** Dos boostings de regresión cuantílica, para los cuantiles 5 % y 95 %, entrenados con las 3,750 de entrenamiento: $[\hat{q}_{0.05}(x), \hat{q}_{0.95}(x)]$. No hay calibración.
3. **CQR.** Los mismos dos modelos, calibrados con el puntaje $s = \max\{\hat{q}_{0.05}(x) - y,\ y - \hat{q}_{0.95}(x)\}$ en las 3,750 de calibración: $[\hat{q}_{0.05}(x) - \widehat{q},\ \hat{q}_{0.95}(x) + \widehat{q}]$ (sección 4).
4. **Conformal, un umbral.** El de la subsección anterior: $\widehat{f}_T(x) \pm \widehat{q}$ con $s = |y - \widehat{f}_T(x)|$.
5. **Conformal por tipo de sección.** El mismo puntaje con un $\widehat{q}$ por grupo.

Método	Cobertura	Urbanas	Rurales	Ancho urbano	Ancho rural
Clásico (lineal normal)	90.3 %	94.9 %	76.6 %	0.32	0.32
Cuantiles sin calibrar	80.9 %	81.8 %	79.1 %	0.21	0.35
CQR	90.1 %	91.8 %	86.1 %	0.28	0.41
Conformal, un umbral	90.0 %	94.8 %	75.6 %	0.32	0.32
Conformal por tipo de sección	90.0 %	90.0 %	90.0 %	0.26	0.47



Lectura. (i) El intervalo clásico cubre 90.3 % en total: aquí la muestra es grande y los errores no están lejos de la normal, así que funciona marginalmente; pero su ancho es el mismo en todas las casillas y, como el conformal de un umbral, cubre de más en las urbanas y de menos en las rurales. Su 90 % depende del modelo; el del conformal, sólo del sorteo. (ii) Los cuantiles sin calibrar cubren 81 %: un modelo de cuantiles, por bueno que sea, no garantiza su nivel en muestra finita. (iii) CQR toma esos mismos cuantiles y, con un solo paso de calibración, recupera 90 % y conserva la adaptación: ancho 0.28 en urbanas y 0.41 en rurales. (iv) Calibrar por tipo de sección es lo único que da 90 % en cada grupo. Errores Monte Carlo de las coberturas menores a 0.4 puntos.

14.5. Verificación con las casillas de 2012

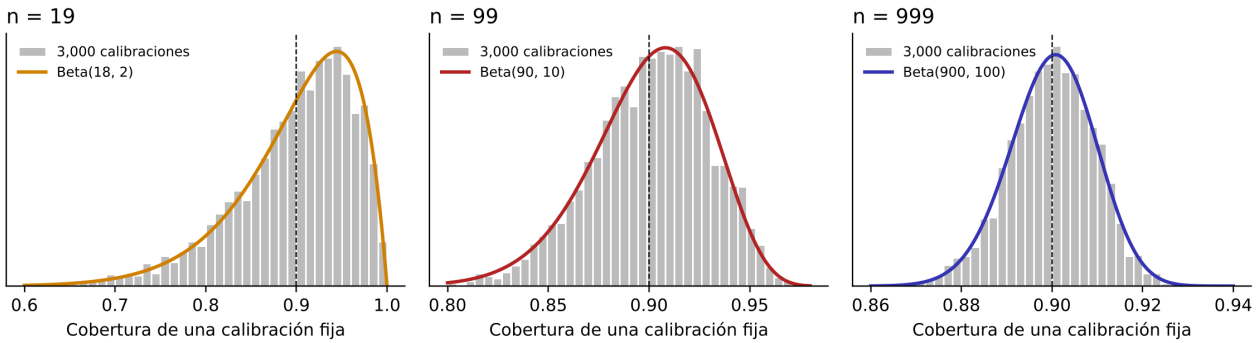
La misma población permite ver la Beta de la sección 12 con datos reales. Aquí no se usa el diseño del conteo rápido (7,500 casillas), sino uno hecho para medir Q con exactitud. El diseño es éste:

1. Respuesta: proporción del voto para PRI-PVEM en la casilla. Covariables: estado, tipo de sección, ruralidad, tamaño de la sección, tipo de casilla y lista nominal.
2. Entrenamiento: una muestra al azar de 2,000 casillas y un boosting de regresión. El modelo se fija una vez.
3. Puntaje: $|y - \widehat{f}_T(x)|$, calculado para las 141,100 casillas restantes. Esa población hace de distribución: un caso nuevo es una casilla al azar de ella.

4. Para $n \in \{19, 99, 999\}$ se repite 3,000 veces: sacar al azar n casillas para calibrar, calcular $\widehat{q} = S_{(k)}$ y medir Q como la fracción *exacta* de las casillas restantes cuyo puntaje queda por debajo de $\widehat{q}$.

Como cada calibración es una muestra al azar de una población grande, los puntajes son prácticamente i.i.d. (Proposición 6.3); sólo 0.3 % de los puntajes se repiten. Los resultados:

n	Media de Q	Teórica	DE de Q	Teórica	$\mathbb{P}(Q < 0.85)$	Teórica
19	0.897	0.900	0.0658	0.0655	0.209	0.198
99	0.901	0.900	0.0295	0.0299	0.055	0.060
999	0.900	0.900	0.0095	0.0095	0.000	< 0.001



Las diferencias son del tamaño del error Monte Carlo (con 3,000 réplicas, el de la media es cercano a $0.066/\sqrt{3000} \approx 0.0012$ para $n = 19$). El mensaje: en 2012 la intercambiabilidad la produce el muestreo al azar, y la teoría se cumple en datos electorales reales. En 2018 la calibración no es una muestra al azar, sino lo que llegó primero (sección 15).

15. Complemento: cuando el sorteo no basta, el conteo de 2018

En la noche de la elección la muestra no llega completa, y las casillas que llegan primero no son una muestra al azar de las que faltan.

15.1. El problema

En 2018 el INE sorteó una muestra estratificada de 7,787 casillas en 350 estratos. Los resultados llegan por remesas durante la noche y el comité publica antes de tener toda la muestra; la estimación de las 22:30 usó 5,254 casillas. La pregunta conforme es local: ¿qué proporción de votos tendrá AMLO en una casilla que todavía no llega? No es un intervalo para el porcentaje nacional.

El cambio de escenario. Dentro de cada estrato las casillas se sortean sin reemplazo: es la urna de la Proposición 6.3. Pero la calibración no es una muestra al azar: son las casillas que llegaron primero. Si la llegada depende del tipo de casilla, el caso nuevo (una pendiente) no es intercambiable con la calibración. Repartir al azar las recibidas entre entrenamiento y calibración no lo arregla: la asimetría está entre recibidas y pendientes.

15.2. Datos

Paquete `quickcountmx` del comité técnico. Se usan las 7,754 casillas de la muestra con hora de llegada registrada: 6,286 enviaron su remesa durante la noche y 1,468 nunca llegaron pero tienen cómputo distrital. La respuesta es la proporción para AMLO, con numerador y denominador siempre de la misma fuente (remesa o cómputo); remesa y cómputo coinciden en la mayoría de las casillas pero no en todas. Las covariables son censales y de diseño (tipo de sección, tipo de casilla, entidad, lista nominal y proporciones de vivienda con internet, piso de tierra, lavadora, refrigerador y celular), sin votos.

Procedimiento. En cada corte (20:00, 21:00, 22:00), las remesas recibidas se reparten al azar mitad para entrenar un boosting de regresión y mitad para calibrar; puntaje $|y - \widehat{f}_T(x)|$, $\alpha = 0.10$; 20 repeticiones del reparto.

15.3. Resultados

Casillas evaluadas	20:00	21:00	22:00
Calibración (mitad de las recibidas)	419	1,371	2,269
Tardías, evaluadas con su remesa	88.5 %	88.2 %	89.2 %
Tardías, evaluadas con su cómputo	88.9 %	88.4 %	89.8 %
Nunca llegaron (cómputo)	82.1 %	81.6 %	82.3 %
Todas las pendientes (cómputo)	87.5 %	86.4 %	86.3 %
rurales	75.8 %	72.2 %	71.2 %
urbanas	91.2 %	91.4 %	92.6 %

Errores Monte Carlo de 0.2 a 0.5 puntos. La fila "nunca llegaron" se obtiene por diferencia: las pendientes con cómputo son las tardías más las 1,468 que nunca llegaron.

Lectura. Cambiar remesa por cómputo en las mismas casillas casi no mueve la cobertura: la medición no es el problema. La caída hasta 86 % viene sobre todo de las casillas que nunca llegaron, que se cubren alrededor de 82 %: son las que menos se parecen a la calibración.

15.4. Un control con p-valores: ¿qué parte es la llegada?

La brecha rural (71–76 %) es tentadora de atribuir a la llegada. El control de la sección 16 muestra que no: si las mismas 6,286 reportantes se reparten *al azar*, ignorando la hora, las rurales se siguen cubriendo alrededor de 76 %. La brecha rural es el fenómeno de "marginal no es por grupo", como en imágenes y crédito. Lo que sí produce la llegada es que la cobertura *global* baje de 90 % a 88 % entre las reportantes tardías, y a 86 % al incluir las que nunca llegaron.

15.5. Extensiones que se mencionan

Calibración por grupo. Un umbral para rurales y otro para urbanas, como en la sección 13.5. Arreglaría la cobertura por tipo de sección si dentro de cada tipo la llegada no seleccionara; no corrige por sí sola la llegada.

Conformal ponderado (Tibshirani, Barber, Candès y Ramdas, 2019). Si calibración y caso nuevo difieren *sólo* en la distribución de X (la calibración es i.i.d. con marginal P_X, el caso nuevo es independiente con marginal $\widetilde{P}_X \ll P_X$, ambos con la misma ley de $Y \mid X$, y el entrenamiento está separado), se pondera cada punto de calibración con $w(x) = d\widetilde{P}_X/dP_X(x)$, incluido el peso del caso nuevo:

$$\mu_x = \sum_{i=1}^{n} \frac{w(X_i)}{W + w(x)} \delta_{S_i} + \frac{w(x)}{W + w(x)} \delta_{+\infty}, \qquad W = \sum_{i=1}^{n} w(X_i),$$

y $\widehat{q}_w(x)$ es el cuantil $1-\alpha$ de μ_x. Con pesos conocidos la cobertura vuelve a ser al menos $1-\alpha$. Es la Proposición 5.3 con pesos: el átomo en $+\infty$ representa al caso nuevo. Si $w(x)/(W + w(x)) > \alpha$ el umbral es infinito: un caso nuevo muy distinto de la calibración no se puede cubrir de manera informativa. En la práctica w se estima y la garantía se degrada según el error de estimación (Lei y Candès, 2021).

Cota sin intercambiabilidad (Barber, Candès, Ramdas y Tibshirani, 2023). Con pesos fijos, la pérdida de cobertura está acotada por cuánto cambia la distribución de los datos al intercambiar cada punto de calibración con el nuevo, medido en variación total. Si los datos son intercambiables, la pérdida es cero.

Sensibilidad. Si la llegada depende del propio voto aun después de observar X, ningún peso basado en X lo corrige. Lo honesto sería suponer que la razón de momios de llegada verdadera difiere de la estimada a lo más por un factor Γ y construir conjuntos válidos para todo ese rango (Jin, Ren y Candès, 2023). Queda como idea a futuro.

El total nacional. No basta sumar intervalos por casilla para obtener uno nacional: faltan cobertura conjunta, pesos y diseño. Para el total, la herramienta natural son estimadores de diferencia o inferencia asistida por predicciones, con la misma advertencia sobre la llegada.

16. P-valores conformes

16.1. El mismo rango, leído como prueba

Para un caso x y una respuesta candidata y, el *p-valor conforme* es

$$p(x, y) = \frac{1 + \#\{i \le n : \ S_i \ge s_T(x, y)\}}{n + 1}.$$

Es la proporción de puntajes, contando al candidato, que son al menos tan raros como el suyo. Contrasta la hipótesis "(x, y) es intercambiable con la calibración". No es un tema nuevo: es el rango de la sección 5 contado desde arriba.

Teorema 16.1 (validez)**.** *Si los puntajes son intercambiables dado T, para todo $\alpha \in (0, 1)$*

$$\mathbb{P}\{p(X_{n+1}, Y_{n+1}) \le \alpha \mid T\} \le \alpha.$$

Sin empates, $p(X_{n+1}, Y_{n+1})$ es uniforme en $\{1/(n+1), 2/(n+1), \ldots, 1\}$.

Demostración sin empates. En la respuesta verdadera, $\#\{i \le n : S_i \ge S_{n+1}\} = n - \#\{i \le n : S_i < S_{n+1}\} = n - (R_{n+1} - 1)$, así que

$$p(X_{n+1}, Y_{n+1}) = \frac{n + 2 - R_{n+1}}{n + 1}.$$

Como R_{n+1} es uniforme en $\{1,\dots,n+1\}$ (Lema 8.1), $n+2-R_{n+1}$ también lo es, y el p-valor es uniforme en la rejilla $\{j/(n+1)\}_{j=1}^{n+1}$. Exactamente $\lfloor \alpha(n+1)\rfloor$ puntos de la rejilla son $\le \alpha$, así que $\mathbb{P}(p \le \alpha \mid T) = \lfloor \alpha(n+1)\rfloor/(n+1) \le \alpha$. ■

Demostración con empates. Con el desempate lexicográfico de la sección 8, sea $p^* = \big(1 + \#\{i \le n : (S_i, U_i) > (S_{n+1}, U_{n+1})\}\big)/(n+1)$, que es uniforme en la rejilla por el caso sin empates. Si $(S_i, U_i) > (S_{n+1}, U_{n+1})$ entonces $S_i \ge S_{n+1}$; así $p \ge p^*$ y $\mathbb{P}(p \le \alpha) \le \mathbb{P}(p^* \le \alpha) \le \alpha$. ■

Proposición 16.2 (el conjunto es la inversión de la prueba)**.** *Para todo x, $C(x) = \{y :\ p(x,y) > \alpha\}$.*

Demostración. Sea $s = s_T(x,y)$ y $m = \lfloor \alpha(n+1)\rfloor$. Como los conteos son enteros,

$$p(x,y) > \alpha \iff \#\{i : S_i \ge s\} > \alpha(n+1) - 1 \iff \#\{i : S_i \ge s\} \ge m \iff \#\{i : S_i < s\} \le n - m.$$

Por otro lado $k = \lceil (n+1)(1-\alpha)\rceil = n+1-\lfloor \alpha(n+1)\rfloor = n+1-m$, porque $\lceil N - a\rceil = N - \lfloor a\rfloor$ para N entero. Así la condición es $\#\{i : S_i < s\} \le k-1$. Si $k \le n$, por el Lema 5.1 equivale a $s \le S_{(k)} = \widehat{q}$. Si $k = n+1$, la condición siempre se cumple, como $s \le \widehat{q} = +\infty$. ■

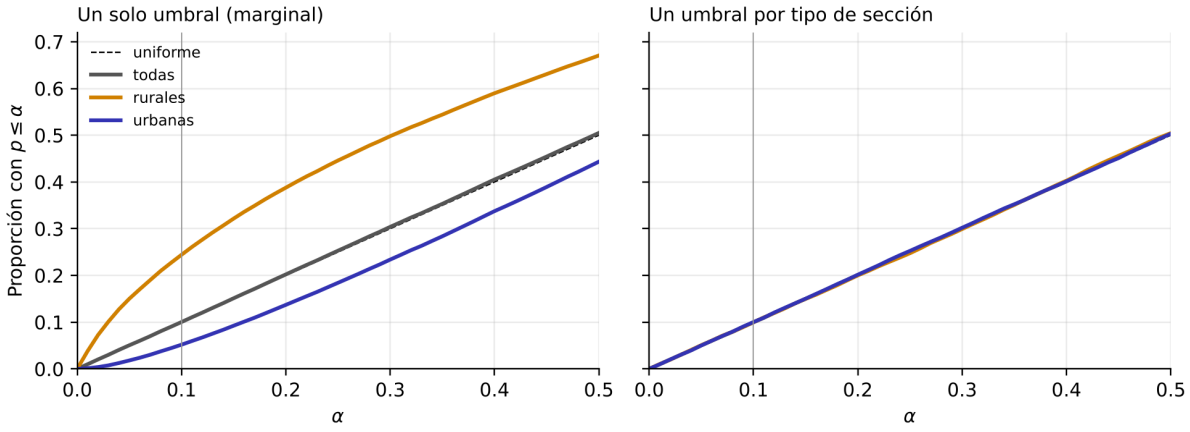
El conjunto que se usó en toda la charla es, entonces, el conjunto de respuestas que una prueba de nivel α no rechaza: la misma dualidad entre pruebas e intervalos de confianza de la estadística clásica.

16.2. Para revisar el supuesto

Cuando la respuesta ya se observó, el p-valor de un caso dice qué tan raro es frente a la calibración. Si la intercambiabilidad se cumple, cada p-valor cumple el Teorema 16.1, así que en un conjunto grande de casos nuevos la proporción con $p \le \alpha$ debe quedar cerca de α (o debajo), para todo α. Una curva de esa proporción contra α que se despega de la diagonal es evidencia contra el supuesto. Los p-valores de casos que comparten calibración no son independientes, así que es un diagnóstico, no una prueba formal; las pruebas formales de intercambiabilidad en línea usan martingalas conformes (Vovk, Gammerman y Shafer, 2005).

Complemento: el conteo rápido de 2012. Con el diseño de la sección 14, se calculan los p-valores de las casillas no muestreadas, con la calibración completa (un solo umbral) o con la calibración de su tipo de sección (un umbral por grupo).

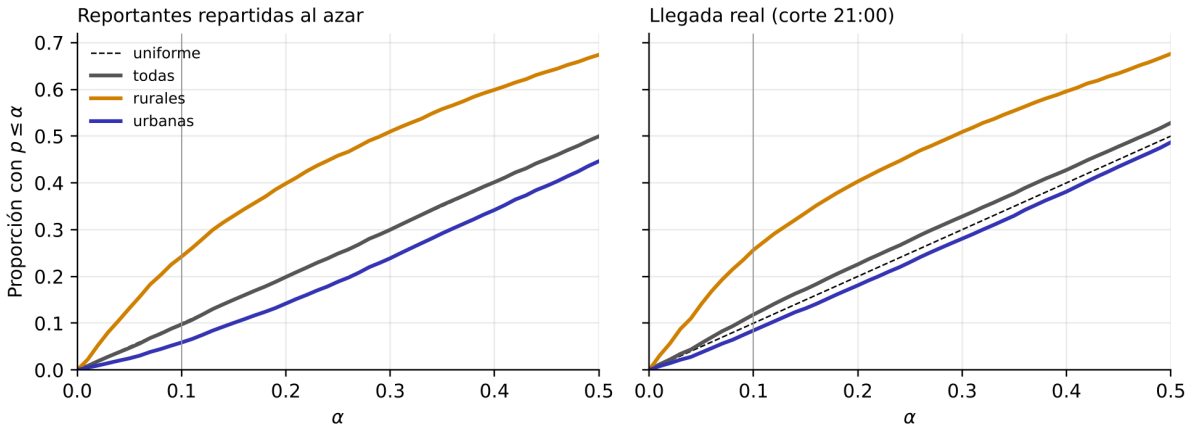
Proporción con $p \leq 0.10$	Todas	Rurales	Urbanas
Un solo umbral	10.0 %	24.4 %	5.2 %
Un umbral por grupo	10.0 %	10.0 %	10.0 %



Con un solo umbral, la curva global cae en la diagonal, como predice el teorema, pero las rurales quedan muy por encima: la intercambiabilidad vale para la población completa, no dentro de cada grupo con una calibración común. Con un umbral por grupo, las tres curvas caen en la diagonal. Con esto se cierra el círculo: el rango que construyó el conjunto es el mismo que permite revisar el supuesto.

En 2018, con la llegada real. Corte de 21:00, reportantes tardías, respuesta y calibración en remesa. Se comparan dos esquemas con los mismos tamaños (1,371 de calibración, 3,545 de prueba): *llegada real*, y un *control* en que las 6,286 reportantes se reparten al azar ignorando la hora. Veinte repeticiones.

Proporción con $p \leq 0.10$	Todas	Rurales	Urbanas
Control al azar	9.7 %	24.2 %	5.9 %
Llegada real	11.8 %	25.7 %	8.4 %



Con el control, la curva global cae en la diagonal, como predice el teorema. Con la llegada real se despega: 11.8 % de p-valores menores que 0.10. Las rurales quedan muy por encima *en los dos esquemas*: su mala cobertura no la causa la llegada, sino que la garantía es marginal, igual que en 2012.

Conformal completo. Split sacrifica datos: unos sólo entrenan y otros sólo calibran. La versión original no parte los datos: para cada candidata y se ajusta el modelo con los $n+1$ puntos $(X_1, Y_1), \ldots, (X_n, Y_n), (x, y)$, se calculan los $n+1$ puntajes y se incluye y si su p-valor supera α. Tiene la misma garantía si el ajuste trata simétricamente a los $n+1$ puntos; el costo es reajustar para cada candidata. Jackknife+ es una alternativa intermedia, con garantía general $1 - 2\alpha$ (Barber et al., 2021).

17. Preguntas probables

¿Cada conjunto tiene 90 % de probabilidad de cubrir?
No. La garantía promedia sobre calibración y caso nuevo. Para una calibración fija la cobertura es un número que, bajo puntajes i.i.d. continuos, varía con ley Beta (sección 12); en 2012 se ve con datos reales.

¿Qué pasa si el modelo está mal?
La garantía marginal se conserva mientras haya intercambiabilidad. Empeora la utilidad (conjuntos más grandes) y puede haber grupos mal cubiertos.

¿Funciona con cualquier modelo?
Sí: redes, boosting, modelos de lenguaje. Sólo se necesita un puntaje fijado antes de calibrar.

¿Cómo elijo el puntaje?
La garantía no depende de él; el tamaño sí. Se elige por utilidad, con datos de entrenamiento o validación, nunca con la calibración (sección 4).

¿La logística no tiene ya sus probabilidades?
Sí, estimadas. El conjunto oráculo tiene garantía para cada x sólo con la probabilidad verdadera; el plug-in no la hereda.

¿Por qué no bootstrap?
Sus justificaciones suelen ser asintóticas y dependen de regularidad. Conformal es exacto para n finita bajo intercambiabilidad.

¿Cuántos datos de calibración necesito?
Al menos $1/\alpha - 1$ para un umbral finito. Para que una corrida no se aleje del nominal, cientos: con $n = 999$ la desviación estándar de la cobertura es 0.0095.

¿Puedo escoger el mejor modelo mirando la calibración?
No, sin perder el teorema. La selección debe hacerse con entrenamiento o validación aparte.

¿Se puede tener cobertura para cada x?
No sin supuestos (teorema de imposibilidad). Sí por grupos definidos de antemano, calibrando en cada uno (sección 13.5).

¿Y con empates?
La cota inferior se conserva; la superior puede fallar. Ocurre con modelos de árboles.

¿Y con series de tiempo?
La intercambiabilidad falla. Hay variantes en línea que ajustan α sobre la marcha y garantizan cobertura promedio de largo plazo (Gibbs y Candès, 2021).

¿Cómo sé si mis datos son intercambiables?
Por cómo se obtuvieron: un sorteo, una partición al azar. Los p-valores conformes sirven para detectar violaciones, no para certificarla (sección 16).

¿El caso del INE demuestra que la llegada causó la caída?
Muestra que la cobertura global baja con la llegada real y no con el control al azar, y que la caída mayor está en las casillas que nunca llegaron. La brecha rural, en cambio, aparece también al azar.

¿Es frecuentista o bayesiano?
La garantía es frecuentista. Una predictiva bayesiana puede usarse como puntaje: si el modelo es correcto da intervalos parecidos a los bayesianos, y si no, conserva la cobertura (Fong y Holmes, 2021).

A. Cuántos datos se usaron en cada ejemplo

En todos los ejemplos $\alpha = 0.10$ y el cuantil es $S_{(k)}$ con $k = \lceil (n+1)(1-\alpha) \rceil$. "Réplicas" es el número de particiones o sorteos al azar; las cifras reportadas son sus medias.

Ejemplo	Total	Entrena	Calibra	Evalúa	Réplicas	Modelo y puntaje
Dígitos	1,797 imágenes de 8×8, tres niveles de ruido al azar	600	500 ($k = 451$)	697	100	Logística multinomial; $1 - \widehat{p}_y(x)$
Crédito	30,000 clientes, 22.1 % incumplen	18,000 (60 %)	6,000 (20 %): ≈4,670 pagan y ≈1,330 incumplen; por clase, un $\widehat{q}$ con cada grupo	6,000 (20 %)	20	Logística sin penalizar y boosting (HistGB); $1 - \widehat{p}_y(x)$
Elecciones 2012, conteo	143,100 casillas; se sortean 7,500	3,750	3,750 ($k = 3{,}376$): ≈2,491 urbanas, 422 mixtas, 804 rurales; 33 sin tipo	135,600 no muestreadas	20	Boosting de regresión; $\lvert y - \widehat{f}_T(x) \rvert$
Intervalos 2012	los mismos 7,500 sorteados	3,750 (el lineal usa las 7,500)	3,750 (CQR y conformal)	135,600	20	Lineal normal, cuantiles 5 %/95 %, CQR, conformal
Beta 2012	143,100 casillas	2,000 (una vez)	$n = 19$, 99 y 999 al azar de las 141,100 restantes	las $141{,}100 - n$ restantes (exacto)	3,000 por cada n	Boosting de regresión; $\lvert y - \widehat{f}_T(x) \rvert$
P-valores 2018	7,754 casillas de la muestra con hora de llegada	mitad de las recibidas	1,371 (corte de 21:00)	3,545 pendientes	20	Boosting de regresión; $\lvert y - \widehat{f}_T(x) \rvert$
INE 2018, complemento	7,754 casillas	mitad de las recibidas	419, 1,371 y 2,269 (cortes de 20, 21 y 22 h)	pendientes	20	Boosting de regresión; $\lvert y - \widehat{f}_T(x) \rvert$

Los valores de k: con $n = 500$, $k = \lceil 501 \times 0.9 \rceil = 451$; con $n = 3{,}750$, $k = \lceil 3{,}751 \times 0.9 \rceil = 3{,}376$; con $n = 19$, 99 y 999, $k = 18$, 90 y 900. En la calibración por grupo de 2012 cada grupo usa su propio n: urbanas $k \approx 2{,}243$, mixtas $k \approx 381$, rurales $k \approx 725$. En crédito por clase, $k \approx 4{,}207$ para los que pagan y $k \approx 1{,}196$ para los que incumplen.

B. Datos y programas

Todas las rutas son relativas a la carpeta `aplicaciones` del repositorio.

Resultado	Programa	Datos
Imágenes (sección 10)	`01_digitos/imagenes.py`	dígitos de `scikit-learn`
Beta con 2012 (sección 14.5)	`03_conteo_2012/beta2012.py`	`quickcountmx`, `nal_2012`
Conteo 2012 (sección 14)	`03_conteo_2012/conteo2012.py`	ídem
Comparación de intervalos 2012	`03_conteo_2012/intervalos2012.py`	ídem
Crédito marginal	`02_credito/credito.py`	UCI (ver `02_credito/README.md`)
Crédito por clase	`02_credito/credito_mondrian.py`	ídem
INE, coberturas	`04_ine_2018/ine.py`	`quickcountmx` (commit 86c75437)
INE, p-valores	`04_ine_2018/ine_pvalores.py`	ídem

Los resultados están en la carpeta `resultados/` de cada aplicación. Las cifras de crédito e INE se reprodujeron exactamente al reejecutar los programas con los datos originales.

Fuentes

Para estudiar, en este orden

1. Angelopoulos, A. N. y Bates, S. (2023). Conformal prediction: A gentle introduction. *Foundations and Trends in Machine Learning*, 16(4), 494–591.
2. Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J. y Wasserman, L. (2018). Distribution-free predictive inference for regression. *JASA*, 113, 1094–1111.
3. Angelopoulos, A. N., Barber, R. F. y Bates, S. *Theoretical Foundations of Conformal Prediction*. Cambridge University Press (arXiv:2411.11824).
4. Tibshirani, R. J., Barber, R. F., Candès, E. J. y Ramdas, A. (2019). Conformal prediction under covariate shift. *NeurIPS*.

Fundamentos

- Vovk, V., Gammerman, A. y Shafer, G. (2005; 2a ed. 2022). *Algorithmic Learning in a Random World*. Springer.
- Shafer, G. y Vovk, V. (2008). A tutorial on conformal prediction. *JMLR*, 9, 371–421.
- Vovk, V. (2012). Conditional validity of inductive conformal predictors. *ACML*, PMLR 25.

Puntajes

- Romano, Y., Patterson, E. y Candès, E. J. (2019). Conformalized quantile regression. *NeurIPS*.
- Sadinle, M., Lei, J. y Wasserman, L. (2019). Least ambiguous set-valued classifiers with bounded error levels. *JASA*, 114, 223–234.
- Romano, Y., Sesia, M. y Candès, E. J. (2020). Classification with valid and adaptive coverage. *NeurIPS*.
- Chernozhukov, V., Wüthrich, K. y Zhu, Y. (2021). Distributional conformal prediction. *PNAS*, 118(48).
- Fong, E. y Holmes, C. (2021). Conformal Bayesian computation. *NeurIPS*.

Cobertura condicional

- Lei, J. y Wasserman, L. (2014). Distribution-free prediction bands for non-parametric regression. *JRSS-B*, 76(1).
- Foygel Barber, R., Candès, E. J., Ramdas, A. y Tibshirani, R. J. (2021). The limits of distribution-free conditional predictive inference. *Information and Inference*, 10(2).
- Gibbs, I., Cherian, J. J. y Candès, E. J. (2025). Conformal prediction with conditional guarantees. *JRSS-B*, 87(4).

Sin intercambiabilidad

- Lei, L. y Candès, E. J. (2021). Conformal inference of counterfactuals and individual treatment effects. *JRSS-B*, 83(5).
- Barber, R. F., Candès, E. J., Ramdas, A. y Tibshirani, R. J. (2021). Predictive inference with the jackknife+. *Annals of Statistics*, 49(1), 486–507.
- Barber, R. F., Candès, E. J., Ramdas, A. y Tibshirani, R. J. (2023). Conformal prediction beyond exchangeability. *Annals of Statistics*, 51(2), 816–845.
- Jin, Y., Ren, Z. y Candès, E. J. (2023). Sensitivity analysis of individual treatment effects: A robust conformal inference approach. *PNAS*, 120(6).
- Gibbs, I. y Candès, E. J. (2021). Adaptive conformal inference under distribution shift. *NeurIPS*.

Datos

- Yeh, I.-C. y Lien, C.-H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2), 2473–2480.
- Alpaydin, E. y Kaynak, C. (1998). Optical recognition of handwritten digits. UCI Machine Learning Repository.
- INE (2018). Informe final del Comité Técnico Asesor de los Conteos Rápidos. Paquete `quickcountmx` (COTECORA).
- Anzarut, M., González, F. y Ortiz, T. (2019). A heavy-tailed multilevel mixture model for the quick count in the Mexican elections of 2018.